

★および★)。x軸は、評価セット全体における推定APIコストを示している。

f: プロジェクトリーダー。*: 主要貢献者。✉: 責任著者。

プレプリント。

1 はじめに

「メディアは、人間の結びつきや行動の規模や形態を形作り、制御する。」

— マーシャル・マクルーハン

言語エージェントにとって、検索は外部コーパスにアクセスし、それを認識するための主要なインターフェースとして機能する。このインターフェースは、検索補助生成 (Lewis et al., 2020; Gao et al., 2023; Singh et al., 2025)、オープンドメインの質問応答 (Trivedi et al., 2022; Press et al., 2023)、およびディープリサーチ (Wei et al., 2025; Chen et al., 2025b) など、幅広い応用を支えている。標準的な検索補助型パイプラインでは、下流の推論が始まる前に、文書がチャンク化され、インデックス化され、確立されたスパース (Robertson et al., 1994) またはデンセ (Karpukhin et al., 2020) の手法を用いてトップkの候補セットにフィルタリングされる。

エージェント時代の到来に伴い、検索エージェント (Zhai, 2025) は反復的に計画を立て、クエリを再構成し、文書を読み込むことが可能となり、より複雑な複数ラウンドにわたる検索行動を実現している (Jin et al., 2025; Jiang et al., 2025; Team et al., 2025b,a; Li et al., 2026b)。しかし、この柔軟性の向上は、各ステップでコーパスのトップkスライスのみを公開する、固定された既製の検索インターフェースによって依然として制約を受けている。この制限は、BrowseComp-Plus (Chen et al., 2025b) などの新たなベンチマークにおいてより顕著になります。これらのベンチマークでは、エージェントが多くのアクション (例えば、中間エンティティの発見、散在する手がかりの集約、厳密な語彙的制約の適用、局所的な文脈を調査した後の検索計画の修正など) を組み立てる必要があります。このような要求の下では、証拠の開示が制限されることが効果的な探索の妨げとなる。その結果、パフォーマンスのボトルネックは、検索後の推論だけでなく、検索インターフェースそのものから生じることになる。

このボトルネックを克服するため、本論文では、**ダイレクト・コーパス・インタラクション (DCI)** を、エージェント主導型検索のための新たな検索インターフェースとして位置づける。エージェントは、従来の意味論的検索エンジンや検索APIにクエリを送信する代わりに、grep、単純なファイル読み取り、シェルコマンド、軽量スクリプトなどの汎用的なターミナルツールを使用して、生のコーパスを直接検索する。既製の埋め込みモデル、ベクトルインデックス、あるいはトップKインターフェースがアクセスを仲介することはなく、コーパス全体が利用可能なまま維持され、意味解釈はエージェント自身に委ねられる。これは、エージェントが戦略的に検索を行うほど強力になった場合 (最近のシステムが示唆しているように、例えばAnthropic, 2026; OpenAI, 2026) が示唆するように、エージェントが戦略的な検索を行えるほど強力になると、特に有益となります。なぜなら、エージェントが検索プリミティブを独自に組み合わせることができるため、推論が始まる前に有用な証拠が破棄されるのを防げるからです。実際には、DCIは、コーパスの探索 (例: find)、完全一致 (例: grep)、局所的な検査 (例: head、tail、またはsed)、および反復的な精緻化のために、小規模ながらも非常に柔軟で組み合わせ可能な一連の操作を提供します。さらに、これらの操作をパイプライン処理することで、語彙的制約を適用したり (例: grep 'foo' file | grep 'bar')、弱い手がかりを組み合わせたり (例: find . | grep 'report' | grep '2024')、局所的な文脈に対して仮説を検証したり (例: grep -n 'keyword' file | head) することが可能である。

DCIの有効性を実証するため、BrowseComp-Plus (Chen et al., 2025b) におけるエンドツーエンドのエージェント検索、マルチホップQAベンチマーク (Yang et al., 2018; Trivedi et al., 2022)、およびランキング指向のIRベンチマーク (Thakur et al., 2021; Su et al., 2025) において評価を行った。BrowseComp-Plusでは、同じClaude Sonnet 4.6バックボーンの下で、検索ツールをQwen3-Embedding-8BからDCIに置き換えることで、精度が69.0%から80.0% (+11.0ポイント) に向上し、コストは1,440ドルから1,016ドル (-29.4%) に削減された。マルチホップQAにおいて、DCIとコマンドラインインターフェースエージェントとしてのClaude Codeを組み合わせることで、平均精度83.0%を達成し、最も強力な検索エージェントベースライン (Gao et al., 2025) を30.7ポイント上回った。IRランキングにおいては、同じ構成で平均NDCG@10が68.5に達し、最良のリトリバルベースライン (Liu et al., 2025) を21.5ポイント上回った。汎用性を実証するため、さらにDCIを、bashとreadのみに依存し、

切り捨てや圧縮といった軽量なランタイムコンテキスト管理戦略を採用した、最小限のターミナルベースのコーディングハネス（Claude CodeやSonnet 4.6ではなく、PiおよびGPT-5.4 nano上に構築されたもの）と組み合わせた。この構成も、QAおよびIRベンチマークにおいてベースラインを一貫して上回る性能を示し、従来の検索ツールと比較してBrowseComp-Plusにおいて性能を向上させると同時にコストを削減している。

さらに、DCIの性能向上の要因を特定するために、制御されたアブレーション実験と軌跡分析を実施した。軌跡レベルの検索パターン（RQ2）、証拠の利用（RQ3）、コーパスの規模（RQ4）、コンテキスト管理（RQ5）、およびツールの使用状況（RQ6）を検証した結果、DCIの優位性は主に「より多くのゴールド文書を抽出すること」に起因するものではないことが判明した。BrowseComp-Plusでは、検索エージェントがすでに一部の、あるいはすべてのゴールド証拠を抽出済みである場合でも、DCIが優位性を示すことが多く、最大の性能向上は、抽出された証拠をより価値の高い、きめ細かな局所的な検索および検証ステップへと変換することから生じている。我々は、このきめ細かなコーパスアクセスモードを「検索インターフェースの分解」と呼ぶ。ここで「分解」とは、

文書全体や段落よりも小さく、より精密な単位に対して操作を行う能力を指す。この利点は、ツール構成が極めて制限された状況下でも持続する。これとは別に、我々のスケーリングおよびコンテキスト管理に関する研究は、DCIの動作範囲と、それを実用的なものにする実行時の選択をさらに明確にしている。

これらの結果は、エージェントシステムにおける検索に関するより広範な見方を示唆している。すなわち、中心的な問いは、単にどの検索エンジンを使用するかということではなく、どのインターフェースがエージェントの推論と最も整合するかということである。モデルが人間の研究者と同様に検索（例えば、仮説の構築、正確なパターンの検証、局所的な文脈の読み取り、クエリの精緻化など）を行えるようになると、圧縮された類似度インデックスがボトルネックとなり、より高解像度のインターフェースの価値が高まる。この観点から、DCIは単なる別のアプローチではなく、能力のあるエージェントのための検索を、単に検索エンジンの設計問題としてではなく、インターフェース設計問題（その粒度によって、エージェントが何を観察し、検証し、それに基づいて行動できるかが決まる）として再定義すべきであるという証拠である（Zhang et al., 2024; Singh et al., 2025）。実際、高密度および疎な検索は、大規模で静的なコーパスに対しては依然としてスケーラブルかつ有効であるが、それらはコーパス・インターフェースというより広範な設計空間における一点に過ぎない。コーパスがローカルで、異種混在であり、絶えず進化し得る実際のエージェント型ワークスペース（Steinberger & OpenClaw Contributors, 2025; Anthropic, 2026）において、標準的なbashターミナルを介したDCIは、オフラインでの埋め込みやインデックス作成を必要とせず、変化するファイルに自然に適応し、エージェントが推論の対象となる環境内で直接動作することを可能にする。

要約すると、本研究は以下の3つの重要な貢献をもたらす：

- *直接コーパス相互作用 (DCI)* を検索パラダイムとして形式化し、多様なエージェント型検索設定において体系的に評価した。
- DCIが文書ランキング、マルチホップQA、エンドツーエンドのエージェントティック検索において競争力のある手法であることを示し、ほとんどのベンチマークにおいて、外部リトリバーに依存することなく競合するベースラインを上回る性能を発揮した。
- DCIの有効性を説明するための概念的枠組みとして「*検索インターフェースの解決*」を導入し、カバレッジおよびローカリゼーション分析による軌跡レベルの証拠を用いてこの見解を裏付けた。

2 関連研究

検索拡張生成 (RAG)。RAG (Guu et al., 2020; Lewis et al., 2020; Borgeaud et al., 2022; Asai et al., 2023; Ram et al., 2023; Gao et al., 2023; Shi et al., 2024) は、「検索→生成」というパイプラインを通じて、大規模言語モデル (LLM) に外部知識を補完する手法である。クエリが与えられると、システムはまずコーパスから関連性のある可能性のある文書を検索し、モデルは検索された証拠を条件として最終出力を生成する。従来のRAGでは、効率的な検索のために、あらかじめ構築されたインデックスを介して検索が行われる。通常、文書はチャンクに分割され、疎表現または密表現に変換された上で、事前にインデックス化される。疎検索はBM25 (Robertson et al., 1994) などの語彙マッチングに依存する一方、密検索は学習済みベクトルに対する最近傍検索を行う (Khatab & Zaharia, 2020; Karpukhin et al., 2020; Izacard et al., 2022; Wang et al., 2022; Li et al., 2023; Zhang et al., 2025)。その後の進展として、LLM ベースの再ランク付け (Sun et al., 2023; Zhuang et al., 2025; Weller et al., 2025) や適応型 RAG (Jeong et al., 2024) などが挙げられ、これらは個々の段階を改善しているものの、根本的な検索構造は同じまま維持されている。

エージェント型検索の台頭。シングルショットの「検索→生成」パイプラインから、多段階の検索エージェントへのパラダイムシフトが進んでいる (Jin et al., 2025; Jiang et al., 2025; Li et al., 2025)。最近のシステム (Team et al., 2025b,a; Li et al., 2026b) は、より大きなコンテキストウィンドウと適応型スキャフォールディングを活用し、長期的な調査を実行している。これらは、反復的に検索を行い、証拠を蓄積し、中間的な観察結果に基づいて計画を精緻化していく。しかし、これらのシステムにおいて、モデルがコーパスにアクセスする唯一の経

路は、意味的な理解をインデックスへと押し上げる固定されたリトリーバーに過ぎない。エージェントの能力が高まり、タスクがより困難になるにつれて (Mialon et al., 2024; Wei et al., 2025; Chen et al., 2025a,b) につれて、ボトルネックは検索後の推論だけでなく、コーパスの意味論を十分に引き出せないインターフェースそのものにもなっていく。我々の研究では、この設計を逆転させ、意味理解をLLMへと下方に移し、LLMに生のコーパスへの直接的かつ高解像度のアクセスを可能にする。

コーディングエージェント。 コマンドラインインターフェース (CLI) を備えた最新のエージェントは、複雑なソフトウェア工学タスクを解決する強力な能力を示している (Liu et al., 2023; Jimenez et al., 2024; Deng et al., 2025; Anthropic, 2025; Merrill et al., 2026; Li et al., 2026a)。SWE-agent (Yang et al., 2024) は、bash、ファイル検索、およびコード編集ツールを備えたエージェントが、直接プロンプティングを大幅に上回る性能を発揮することを示しており、一方、Agentless (Xia et al., 2025) は、単純なgrepと読み込みのパイプラインでさえ、完全なエージェントフレームワークに匹敵する性能を発揮できることを実証している。OpenHands (Wang et al.,




図2：エージェント型検索のための2つの検索インターフェース。（左）リトリバーを介した検索は、コーパスに対するオフラインインデックス作成とリトリバーに依存する。エージェントはリトリバーにクエリを送信し、返された上位 k 件の候補について推論を行う。（右）対照的に、直接コーパス操作では前処理や独立したリトリバーを省略する。エージェントは、grep、glob、bashなどの汎用ターミナルツールや軽量スクリプトを用いて生のコーパスを直接検索し、きめ細かなパターンマッチングと正確な証拠の特定を可能にする。

2025) およびAider (Gauthier, 2024) は、ターミナルベースのコーディングエージェントを成熟したパラダイムとしてさらに定着させた。タスクの完了にとどまらず、Sutawikaら (2026) は最近、CLIプリミティブのみでも正確なコードの特定が可能であることを示している。Subramanianら (2025) は、生のPDFを対象としたツール拡張型キーワード検索エージェントが、文書QAにおいてベクトルデータベース型RAGに匹敵する性能を発揮し得ることを示しているが、我々はエージェント型検索のためのより広範な検索インターフェースとして、コーパスとの直接的な相互作用を研究している。これらのシステムは、grep、ファイル読み取り、およびシェルコマンドが、エージェントがコードファイルを作成・編集し、リポジトリ全体をナビゲートし、テストやその他のプログラムを実行するための主要な情報チャネルとして機能することを立証している。CLIツールの主な利点は、その精度だけでなく、パイプラインを介した柔軟性と組み合わせ可能性にある (GNU Project, 2025)。本研究では、CLIをエージェント型検索のための新たな検索媒体として位置づけ、grep、ファイル読み取り、シェルコマンドなどの汎用ターミナルツールを、コーパスへの高解像度のインターフェースとして扱う。

3 コーパスとの直接的な相互作用

本論文では、図2に示すように、エージェント検索中にエージェントがコーパスにアクセスする方法に関する2つの広範なパラダイムを比較することを目的とする。リトリバーを介したアクセスでは、コーパスとの相互作用は従来のリトリバーによって仲介される。すなわち、エージェントはクエリを構築し、ランク付けされたトップ k の文書またはスニペットのリストを受け取り、返された候補に基づいてクエリを再構築しながら反復処理を行う。この設定では、エージェントの観察対象は、リトリバーが公開することを選択した内容（通常は短いスニペットと文書識別子）にほぼ限定され、すべての証拠はリトリバーのスコアリングおよびランキングインターフェースを経由しなければならない。

直接コーパス対話 (DCI) では、エージェントは埋め込みモデル、ベクトルインデックス、検索APIをすべてバイパスし、代わりに汎用コマンドラインインターフェースを通じて生のコーパスと対話します。具体的には、エージェントは、完全一致や正規表現による一致を検索するために grep や rg といったツール呼び出しを行い、構造的なナビゲーションのために find や glob を使用し、一致箇所周辺のローカルコンテキストを調査するために、対象を絞ったファイル読み取りや軽量のスクリプトを実行します。したがって、その結果として得られる観測値は、固定形式のランク付けされたリストではなく、ツールの出力（例：周辺コンテキストを含む一致スパン、ファイルパス、カウント、メタデータ）となります。

3.1 DCIエージェントの実装

我々は、2つのエージェント・スキヤフォールドおよび制御されたアブレーションの下でDCIをインスタンス化します。どちらの実装も、ターミナルツールやファイル読み取りを通じて生のコーパスを直接検索します。両者の違いは実行時のサポートのみであり、これによりDCIインターフェースの中核的な効果と、追加のハーネス設計とを分離することが可能になります。

DCI-Agent-Lite：最小限のスケルトン。 インターフェースの変更を可能な限り明確に隔離するため、Pi ([Zechner & Pi Contributors, 2026](#)) を基に、生のターミナル操作に限定した軽量なターミナルコーディングエージェント「DCI-Agent-Lite」を導入した。このエージェントは、bashおよびファイル読み取りを通じてコーパスにアクセスし、grepやrgなどの汎用シェル操作を用いて語彙マッチングを行う。

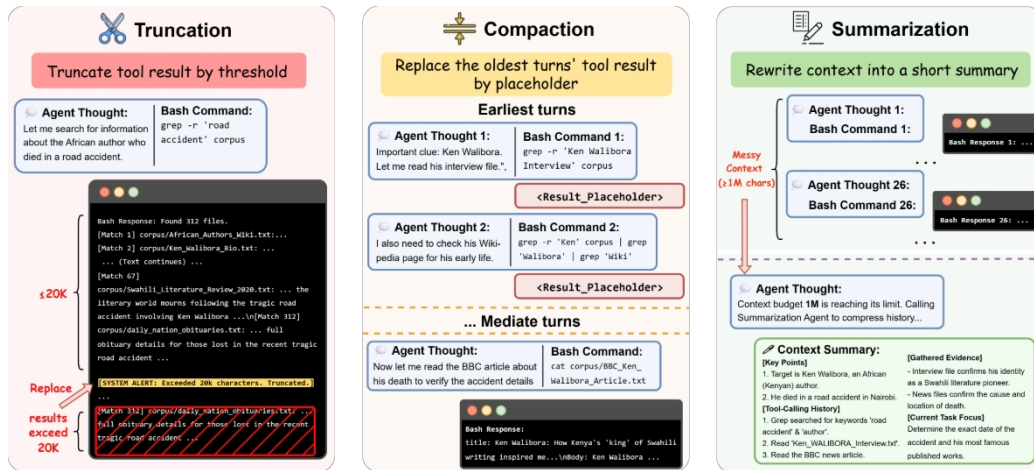


図3：長期DCIにおける実行時コンテキスト管理戦略の可視化。検索軌跡の構造を維持しつつ、コンテキストの負荷を軽減するために、3つのメカニズム（すなわち、ツール結果の切り捨て、履歴の圧縮、要約）を採用している。

findやglobによるファイル検出、および軽量スクリプトを併用する。重要な点として、DCI-Agent-Liteには検索固有のモジュールが含まれていない。つまり、オフラインインデックス作成、高密度リトリーバー、再ランク付け機能は一切存在しない。この最小限の基盤により、改善効果が主にDCIパラダイムに起因すると断定できる制御された実験が可能となる。

DCI-Agent-CC：より強力な基盤。より高性能なハネス下で同じパラダイムの性能限界を探るため、既製のCLI エージェントであるClaude Code（Anthropic, 2025）を用いてDCIを実装した。このバリエーションをDCI-Agent-CCと呼ぶ。DCI-Agent-Liteと比較して、より強力なプロンプティング、より堅牢なツールのオーケストレーション、および組み込みのコンテキスト処理を提供し、これらが相まって、長期的な探索や異種コーパスにおける安定性が向上する。なお、我々はDCI-Agent-CCを、別の検索手法ではなく、DCIのより強力な実装例として扱っている。これは依然として、生のコーパスに対してターミナルツールのみを通じて動作し、埋め込みリトリーバーや検索APIを一切呼び出さない。

3.2 DCIのための実行時コンテキスト管理

grepやrgの呼び出しを繰り返すと、

表1：実行時コンテキスト管理のプロファイル。

多数の一致を返す可能性があり、ファイルを開いたり、

周辺のコンテキストを抽出する際に、長大なテキスト範囲が露呈する可能性がある。長期的な軌跡において、これらの観測結果は急速に蓄積し、モデルの有限なコンテキストウィンドウを超える可能性がある。したがって、ランタイムは以下の2つの相反するニーズのバランスをとらなければならない：(1) 証拠と中間コンテキストを保持すること、

(1) 後の推論のための制約を保持し、(2) 探索が進むにつれて新たな観測結果を取り入れる余地を確保すること。

長期的なDCIをサポートするため、DCI-Agent-Liteには、図3に示すような軽量な実行時コンテキスト管理レイヤーを装備しています。このレイヤーは、3つのメカニズムを中心に構築されています。

- 「切り捨て」は、各ツール呼び出しからのテキストを、ライブの作業コンテキストに再挿入する前に上限値

まで切り詰めるもので、観察が行われたことを保持しつつ、ターンごとの冗長性を制限します。

- **圧縮**は、メモリ内で行われる LLM を一切使用しない操作であり、蓄積されたツール出力が設定された閾値を超えた時点で、古いツール結果ターンの内容を消去し、ツール呼び出しの構造を保持した短いプレースホルダーに置き換えます。
- **要約**は、より積極的な介入戦略であり、コンテキストの圧迫がさらに高まった場合、最新のコンテキストをそのまま維持しつつ、圧縮された履歴をモデル生成の要約に置き換えます。

制御された分析を行うため、表1に示すように、我々は少数のコンテキスト管理ポリシー群を実装しており、それぞれがこれらのメカニズムの異なるサブセットを、異なる積極性で有効にしている。具体的には、L0はコンテキスト管理を一切行わない。L1は切り捨てのみを適用し（各ツール結果を50,000文字に制限）、L2～L4はより厳格な20,000文字の上限を採用する。L3はさらに圧縮を有効にし、蓄積されたツール結果の内容が240,000文字を超えた時点でトリガーされ、直近の12ターン以外のすべてを圧縮する。L4では、圧縮後に要約処理がさらに実行される。推定されたコンテキストトークン数が依然として閾値を超える場合、ランタイムは圧縮された履歴をモデル生成の要約に置き換えつつ、最新の20,000トークンを保持し、1つのセッション内で要約処理が3回連続で失敗した後は、それ以降の試行を抑制する。

なお、これらのポリシーは検索インターフェースそのものを変更するものではありません。これらは、長期間にわたる検索において、モデルの作業コンテキスト内にツールを介した証拠がどの程度保持されるかという点のみを変更するものです。

3.3 DCIの評価：カバレッジと局所化

下流タスクにおける回答の精度は、もちろんDCIを評価する上で重要な指標である。しかし、精度だけでは、DCIと従来のリトリバーを介したアクセスが、質的に異なる方法でどのように成功または失敗するかを捉えるには不十分である。検索エンジン媒介型アクセスは通常、高水準のリコール率を提供しますが、正確な文字列の一致、弱い語彙シグナルの結合、および次のステップへの正確なスパンレベルのトリガーに対する制御は限定的です。対照的に、DCIはより高解像度の検索インターフェースを提供します。エージェントが有用な文書に到達すると、特定の用語を直接調査し、ファイル全体を開き、新しいエンティティや制約を抽出し、局所化された証拠に基づいたフォローアップ検索を即座に開始することができます。これらの違いをプロセスレベルで特徴づけるため、2つの軌跡レベル指標を導入する。「カバレッジ」は、軌跡が関連する（ゴールド）文書をまったく抽出できたかどうかを測定し、広範な証拠へのアクセスを反映する。「ローカライゼーション」は、軌跡が抽出された各ゴールド文書内で、小さく実用的な証拠スパンにどれだけ効率的に絞り込めたかを測定し、文書内の証拠の特定を反映する。

形式的には、 $D^*(q)$ を質問 q に対するゴールド文書とし、 $M(q, \tau) \subseteq D^*(q)$ を軌跡 τ に沿って抽出された文書とする。ここで、文書は、検索されたスニペットとして、あるいはツール呼び出しによって返されたファイルとして、記録されたトレースに明示的に出現した場合に抽出されたものとみなされる。

カバレッジ。以下の3つのカバレッジ集計値を報告する：

$$\begin{aligned} \text{カバレッジ}_{\text{any}}(q, \tau) &= \mathbf{1}[|M(q, \tau)| \geq 1]、\text{カバレッジ}_{\text{平均}}(q, \tau) = \frac{|M(q, \tau)|}{|D^*(q)|} \text{ および} \\ \text{カバレッジ}_{\text{全}}(q, \tau) &= \mathbf{1}[|M(q, \tau)| = |D^*(q)|]。 \end{aligned} \quad (1)$$

経験的に、これらのカバレッジスコアはリーチメトリクスである。カバレッジ_{any}は、軌跡が少なくとも1つのゴールド文書を抽出するかどうかを測定し、カバレッジ_{mean}は、各文書が抽出されたかどうかのゴールド文書全体に対する平均値であり、カバレッジ_{all}は、ゴールド文書の全セットが抽出されるかどうかを測定する。したがって、これらは、抽出された文書内でのきめ細かな証拠の利用というよりは、広範な証拠へのアクセスを反映している。

局所化。軌道 $\tau = (o_1, \dots, o_T)$ を一連の観測値の列とする。各観測値 o_i について、 $R(o_i) = \{(d_{i,1}, \sigma_{i,1}), \dots, (d_{i,n}, \sigma_{i,n})\}$ と定義する。ここで、 n は観測値 o_i に含まれる公開アイテムの数、 $d_{i,i}$ は対応する文書、 $\sigma_{i,i}$ は $d_{i,i}$ に対して公開されたスニペット、そして $\ell_{i,i} = |\sigma_{i,i}|$ はその文字長である。観測 o_i のスニペット長リストを $\ell_i = (\ell_{i,1}, \dots, \ell_{i,n})$ と表記する。分析の単位として、行ではなく固定幅の文字セグメント（その長さは c_{seg} 文字）を用いる。これは、多くの Web や PDF へのエクスポートでは、レイアウトが長い行に圧縮され、行の境界が証拠の粒度を信頼できる指標とならないためである。

局所化は、以下の正規化に基づいて行われます。

$$\nu(x) = \max 1, \frac{x}{c_{\text{seg}}}, \quad \psi(a; b) = \max 1 - \frac{\log a}{\log b}, 0 \quad (1 \leq a \leq b, b > 1 \text{ の場合}), \quad (2)$$

ここで、 $\psi(a; 1) = 1$ とする。ここで、 $\nu(x)$ は文字長をセグメント数に写像し、 $\psi(a; b)$ は a が b に対して小さい場合に高いスコアを割り当てる。

観測 o_i において、ゴールド文書 d^* とアラインメントされた i 番目の候補 $d_{i,i}$ について、次のように定義する。

$$\text{seg-score}(d_{i,i}; d^*) = \psi(\nu(\ell_{i,i}); \nu(|d^*|)) \text{ と定義する。} \quad (3)$$

このスコアは、抽出されたスニペットが完全なゴールド文書内でどれほど局所的であるかを測定するもので、抽出された範囲が文書に対して相対的に小さいほど高い値が割り当てられる。ここで、 $\ell_{t,i}$ は観測 o_i における候補 $d_{t,i}$ によって抽出されたスニペットの文字数であり、 $|d^*|$ は完全なゴールド文書の文字数である。ツールの出力からスニペットへの DCI 固有のマッピングは、実装に依存する。詳細については §A.3 を参照のこと。

抽出された各ゴールド文書 d^* について、 $H(d^*, \tau)$ を軌跡 τ におけるアラインメントされた候補の集合とする。 d^* における最良の局在化を次のように定義する。

$$s(d^*, \tau) = \max_{d, l \in H(d^*, \tau)} \text{seg-score}(d_{t,i}; d^*) \quad (4)$$

次に、抽出されたゴールド文書について集計を行う：

$$\text{localization}(q, \tau) = \frac{1}{|M(q, \tau)|} \sum_{d \in M(q, \tau)} s(d^*, \tau) \quad (5)$$

すなわち、 $\text{localization}(\cdot, \cdot)$ は、抽出された各ゴールド文書について達成されたセグメントレベルの最良スコアの、軌跡レベルでの平均である。経験的に、 $\text{localization}(\cdot, \cdot)$ は文書内メトリクスである。有用な文書に到達したことを前提として、軌跡が小さく実用的な証拠範囲に絞り込めるかどうかを検証する。したがって、 localization スコアが高いことは、エージェントが単に適切な文書に到達しているだけでなく、そこから集中した証拠を抽出していることを示している。

4 実験

4.1 実験設定

実装の詳細。まず、DCI 用の 2 つのスケルトンの実装について詳述する。*DCI-Agent-Lite* は、`bash` と `read` のみを公開する最小限の Pi ベースのハーネスであり、長期的な探索をサポートするための軽量のランタイムコンテキスト管理機能を備えている。（特に断りが無い限り、主要な結果では L3 を、アブレーション実験では L4 を使用する。）*DCI-Agent-ClaudeCode (CC)* は Claude Code を基盤としており、ウェブ検索、ウェブフェッチ、サブエージェントを無効化し、回答の漏洩を防ぐためにデータディレクトリへのアクセスをブロックしている点を除き、デフォルトの設定に従っている。特に断りが無い限り、DCI-Agent-Lite は GPT-5.4 nano (OpenAI, 2026) をベースモデルとして使用しており、厳しいリソース制約下で DCI を評価するための軽量な設定を提供する。対照的に、DCI-Agent-ClaudeCode (CC) はベースモデルとして Claude Sonnet 4.6 (Anthropic, 2026) を使用しており、予算制約が緩和された状況下でこのパラダイムの性能上限を探るための高容量な設定を提供します。推論の労力は、GPT-5.4 nano では「高」、Claude Sonnet 4.6 では「中」に設定し、両エージェントの最大ターン予算は 300 とした。エージェントのプロンプトに関する詳細は、§C に記載している。

ベンチマーク。DCI-Agents を以下の 3 つのベンチマークファミリーで評価する：

- **エージェント型検索。**エージェントの深層検索能力を評価するために、BrowseComp Plus (Chen et al., 2025b) を使用する。公式に公開されたコーパスを採用しており、これには QA を裏付けるゴールド文書と、注意をそらす文書（ディストラクター）の両方が含まれている。後述する検索エージェントのベースラインについては、オフライン検索エンジンとして、Qwen3-Embedding-8B 埋め込み (Zhang et al., 2025) から構築された公開済みの FAISS インデックスを追加で使用している。
- **知識集約型 QA。**コーパス検索を用いたマルチホップ QA を評価するため、NQ (Kwiatkowski et al., 2019)、TriviaQA (Joshi et al., 2017)、Bamboogle (Press et al., 2023)、HotpotQA (Yang et al., 2018)、2WikiMultiHopQA (Ho et al., 2020)、および MuSiQue (Trivedi et al., 2022) を組み込み、コーパス検索を用いたマルチホップ QA を評価する。先行研究 (Jin et al., 2025; Gao et al., 2025) に倣い、コーパスとして 2018 年版

ウィキペディア・ダンプ (Karpukhin et al., 2020) を使用する。検索エージェントのベースラインについては、E5埋め込み (Wang et al., 2022) を用いてインデックスを構築する。

- *IR* ランキング。ランキング評価には、BRIGHTベンチマーク (Su et al., 2025) からの4つのデータセット (生物学、地球科学、経済学、ロボット工学) と、BEIRベンチマーク (Thakur et al., 2021) からの2つのデータセット (ArguAnaおよびSciFact) を採用した。

ベンチマークの詳細については、§A.1を参照のこと。

表2：マルチホップQAベンチマークにおける精度。Δ Avg. は、最も強力な検索エージェントベースラインであるASearcher-Local-14Bに対する平均精度の向上度を示す。**太字**および下線付きの項目は、各列における最良の結果および2番目に良い結果をそれぞれ示す。

モデル	NQ	豆知識	パン。	火鍋	2Wiki	MuSiQue	平均	Δ 平均
検索エージェント								↓ 7.0
R1-Searcher-7B	58	50	54	46	40	24	45.3	↓ 5.6
Search-R1-32B	56	46	52	44	50	32	46.7	↓ 34.6
ZeroSearch-7B	26	30	18	10	18	4	17.7	↓ 14.6
Verl-Tool-Search-7B-DAPO	56	44	32	50	32	12	37.7	
ASearcher-Local-14B	56	58	62	58	56	24	52.3	–
DCI捜査官								
DCI-Agent-Lite (GPT-5.4 nano)	<u>72</u>	<u>84</u>	<u>72</u>	<u>72</u>	<u>68</u>	<u>40</u>	<u>68.0</u>	↑ 15.7
DCI-Agent-CC (Sonnet 4.6)	78	96	80	88	82	74	83.0	↑ 30.7

表3：IRランキングベンチマークにおけるNDCG@10。Δ Avg. は、最も強力な従来型検索ベースラインであるReasonRank-32Bに対する平均精度の向上幅を示す。**太字**および下線付きの項目は、各列における最良の結果および2番目に良い結果をそれぞれ示す。

	BRIGHT				BEIR		概要	
方法	生物学・地球科学・経済学・ロボティクス・ArguAna・SciFact						平均	Δ 平均
スパースおよびデンセ検索								↓ 26.7
BM25	18.9	27.2	14.9	13.6	31.5	15.8	20.3	↓ 13.9
OpenAI-text-emb-3-large	23.3	26.7	19.5	12.8	58.1	58.1	33.1	↓ 7.7
GTE-Qwen2-7B-Instruct	30.6	36.4	17.8	13.2	62.7	75.3	39.3	↓ 10.8
ランク-R1-14B	31.2	38.5	21.2	22.6	31.3	72.2	36.2	
ランク1-32B	49.7	35.8	22.0	22.5	57.6	74.8	43.7	↓ 3.3
ReasonRank-32B	58.2	48.9	<u>36.6</u>	33.9	28.7	<u>75.5</u>	47.0	−
DCIエージェント								
DCI-Agent-Lite (GPT-5.4 nano)	<u>60.0</u>	<u>50.8</u>	32.3	<u>42.4</u>	<u>81.9</u>	72.7	<u>56.7</u>	↑ 9.7
DCI-Agent-CC (Sonnet 4.6)	77.1	69.0	46.8	56.8	85.3	75.7	68.5	↑ 21.5

ベースライン。 結果を文脈的に理解するために、2つのカテゴリーのベースラインを含めています：

- **検索エージェント。** BrowseComp-Plus では、BM25 および Qwen3-Embedding-8B を使用し、GPT-5 (OpenAI, 2025b)、o3 (OpenAI, 2025d)、GLM-4.7 (Z.AI, 2025)、Claude Sonnet 4.5 (Anthropic, 2025)、および Claude Sonnet 4.6 (Anthropic, 2026) を組み合わせています。知識集約型QAについては、R1-Searcher (Song et al., 2025)、Search-R1 (Jin et al., 2025)、ZeroSearch (Sun et al., 2025)、Verl-Tool-Search (Jiang et al., 2025)、ASearcher (Gao et al., 2025) など、一般的に採用されているエージェント型検索のベースラインと比較する。
- **スパースおよびデンシトリート。** IRランキングについては、BM25 (Robertson et al., 1994)、OpenAI-text-embedding-3-large (OpenAI, 2024)、GTE-Qwen2-7B-Instruct (Li et al., 2023)に加え、推論指向の再ランク付けアルゴリズムであるRank-R1 (Zhuang et al., 2025)、Rank1 (Weller et al., 2025)、およびReasonRank (Liu et al., 2025) とも比較を行う。

ベースラインの実装に関する詳細は、§A.2 に記載されている。

4.2 主な結果

RQ1: 成熟したDCIエージェントはすでに優れた性能を発揮できるか？ その答えは「はい」である。我々は、3つの代表的な設定において一貫した証拠を示す。




図4：左：Sonnet 4.6バックボーンを用いたBrowseComp-Plusの全830問における結果。DCI-Agent-CCと、Qwen3-Embedding-8Bをリトリバーとして使用するリトリブ型エージェントを比較している。右：DCI-Agent-CCの全実行におけるツール呼び出しとBashインテントの分布。主要なBashツールが10の具体的なコマンドインテントにどのように分解されるかを示している。

エージェント型検索。図1に示すように、従来のリトリバーをDCIに置き換えることで、BrowseComp-Plusにおいて大幅な性能向上が得られる。具体的には、同じClaude Sonnet 4.6バックボーンを使用し、Qwen3-Embedding-8BをDCIに置き換えることで、精度は69.0%から80.0% (+11.0ポイント)に向上し、コストは1,440ドルから1,016ドル (-29.4%)に削減された。特に、DCI-Agent-CCは、対応するリトリブ型モデルを上回るだけでなく、全体として最も強力なリトリブ型ベースラインであるGPT-5 + Qwen3-Embedding-8B (71.7%)をも8.3ポイント上回っています。一方、DCI-Agent-Lite (GPT-5.4 nano) は、性能とコストのバランスに優れています。わずか93ドルのコストで62.9%の精度を達成し、o3 + Qwen3-Embedding-8B (66.0%)といった大幅に強力な検索エージェントと互角の競争力を維持しつつ、コストを647ドル削減しています。これらの結果は、DCIが優れたディープリサーチ精度と高いコスト効率を実現できることを示している。

知識集約型QA。表2に示すように、DCIエージェントは知識集約型QAにおいて、リトリブ型エージェントのベースラインを一貫して上回っている。DCI-Agent-CCは平均精度83.0%を達成し、最も優れたベースラインであるASearcher-Local-14B (52.3%)を30.7ポイント上回っている。一方、DCI-Agent-Liteも68.0%という競争力のある精度を示している。この性能向上は、マルチホップのベンチマークにおいて特に顕著である。ASearcher-Local-14Bと比較して、DCI-Agent-CCはHotpotQAで30ポイント、2Wikiで26ポイント、MuSiQueで50ポイントの性能向上を達成している。6つのデータセットすべてにおいて、DCI-Agent-CCとDCI-Agent-Liteが上位2位を占めており、これは、複雑で多段階にわたる証拠の集約と推論において、DCIが従来のリトリバル拡張パイプラインに代わる有力な選択肢であることを示している。

IRランキング。表3に示すように、DCIエージェントはIRランキングにおいて、従来のリトリバルベースラインに対して明確な優位性を示している。DCI-Agent-CC (68.5%)は6つのデータセットすべてで最高のNDCG@10スコアを達成し、最も強力なリトリバルベースラインであるReasonRank-32B (47.0%)を平均で21.5ポイント上回った。DCI-Agent-Liteも依然として高い競争力を維持しており、平均NDCG@10が56.7で総合2位となり、最も優れた検索ベースラインを9.7ポイント上回っている。これらの結果は、DCIパラダイムがランキングにおいて有効であることを示唆している。

これらの結果を総合すると、DCIは多様な検索および推論タスクにおいて、優れた性能と良好なコスト効率を両立させる有望な運用方式であることが示唆される。次に、制御されたアブレーション実験および軌跡レベルの分析を通じて、こうした性能向上の背後にあるメカニズムを検証する。

4.3 制御されたアブレーション実験とメカニズム解析

RQ2: なぜDCIが有効なのか？我々の分析によると、DCIの優位性は、ゴールド文書の再現率の高さというよりも、柔軟で構成可能なbashコマンドを通じた、証拠のきめ細かな発見、構成、および活用に起因していることが判明した。図4（左）に示すように、同じSonnet 4.6バックボーンを使用した場合、DCI-Agent-CCは、対応する検索エージェントが見逃した176件のBrowseComp-Plus質問に正しく回答しているのに対し、逆のパターンを示すのはわずか76件である。重要な点として、この差は主に検索の完全な失敗によるものではない。176件のCC-winケースのうち、DCI-Agent-CCによって検索されたゴールド文書が1つもないケースはわずか34件のみである。

表4：BrowseComp-Plusサブセット（ $n = 100$ ）における軌跡分析。§3.3で述べたように、カバレッジは各ゴールド文書ごとのヒットリストに対して、「any」、「mean（リコール）」、「all」の3つの集計方法を用いて計算される。平均局在化（Avg. localization）は、一致したゴールド文書のみを対象に、セグメントレベルの最良の局在化スコアを平均化したものである。コストはエージェント側のコストのみを反映している。精度の差

手法	平均ツール ↓	コスト / q (\$) ↓	任意	平均（リコール） ↑	すべて ↑	平均局在化 ↑	Acc. ↑	精度の 差
<i>検索エージェント (GPT-5.4-nano)</i>								
BM25	19.07	0.0527	63.0	42.8	17.0	23.5	32.0	↓ 13.0
Qwen3-Embedding-8B	17.55	0.0498	74.0	56.7	28.0	21.7	45.0	—
<i>DCI-Agent-Lite (GPT-5.4-nano)</i>								
直接的な相互作用 (L4)	35.35	0.1021	70.0	28.0	1.0	48.4	73.0	↑ 28.0

検索エージェントであり、残りの142件はすでに少なくとも1件のゴールド文書を抽出している。これらのエラーは2つのパターンに分類される：部分チェーンの失敗（ $0 < \text{リコール} < 100$ 、83件）は、検索によって次のステップへ進むための証拠が一部は提示されたものの不十分であった場合であり、検索後の失敗（リコール = 100、59件）は、すべてのゴールド文書が抽出されたものの、それらをうまく活用できなかった場合である。図4（右）のツール分布は、この解釈を裏付けている。DCI-Agent-CCは主にBash（62.4%）とGrep（33.0%）に依存しており、ここでGrepとはClaude Codeに組み込まれたファイル検索プリミティブであり、grepスタイルの語彙検索にほぼ相当する。Bash内での使用状況は、連鎖検索（22.3%）、ローカルコンテキストの確認（18.0%）、正規表現マッチング（17.0%）、ファイルの特定（14.0%）に集中しており、文書全体の読み込みはわずか9.1%を占めるに過ぎない。これらのパターンを総合すると、DCIの利点は、Bashのインタラクションが持つ表現力豊かで構成可能な性質を活用して、語彙的制約を構成し、正確なスパンを検証し、有望なスニペットを選択的に証拠へと展開することにあることが示唆される。

RQ3: DCI と検索を区別する行動上のトレードオフとは何か？ この質問は、DCI が何を得て、何を犠牲にしているかを明らかにする。表4の重要なパターンは、DCI-Agent-Liteが、より多くのゴールド文書を網羅的に回収することで優位に立っているわけではないという点である。そのゴールド文書の平均カバレッジはQwen3-Embedding-8Bよりもはるかに低い（28.0 対 56.7）が、カバレッジ_{any}スコアは同程度（70.0 対 74.0）であり、一方で局在化スコアは劇的に高い（48.4 対 21.7）。これは重要な点である。なぜなら、BrowseComp-Plusの質問には通常、1〜4件のゴールド文書しか含まれていないからだ。そのような状況下では、DCIが1件の有用なゴールド文書を抽出できれば、広範な検索からきめ細かな精査と検証へと切り替えることができる。事実上、DCIは網羅的なゴールドチェーンの回復を、高解像度の局所的な進捗と引き換えにしている。つまり、関連する文書を十分な頻度で見つけ出し、その後、すでに到達した文書から実質的に多くの価値を抽出するのだ。このパターンは、平均カバレッジが低く、ツール呼び出し数がおよそ2倍であるにもかかわらず、+28ポイントの精度向上が観察されたことと一致している。DCI-Agent-Liteの検索パターンに関する追加の分析は、§B.1で提供されている。




図5：BrowseComp-Plusサブセット（ $n = 100$ ）におけるDCI-Agent-CCのコーパススケーリング結果。

表5：BrowseComp-Plusサブセット（ $n = 100$ ）におけるツールプロファイルの除去実験。太字は最良の結果を示す。

手法	平均ツール数 ↓	コスト / q (\$) ↓	精度 ↑
<i>検索エージェント (GPT-5.4-nano)</i>			
BM25	19	0.0527	32
Qwen3-Embedding-8B	18	0.0498	45
<i>DCI-Agent-Lite (GPT-5.4-nano)</i>			
read + grep (L4)	19	0.0355	61
bashを開く (L4)	35	0.1021	73

RQ4: DCIはコーパスサイズに対してどのようにスケーリングするか？ 図5に示すように、DCIには明確な動作

範囲がある。検索深度においては良好にスケーリングするが、検索幅においてはコストが急速に増加する。BrowseComp-Plusコーパスを、元のセットにFineWeb (Penedo et al., 2024) からの追加のディストリビューターを注入することで、10万文書から20万文書に拡張した。この変更により、DCI-Agent-CCは質問1件あたりのツール呼び出し数が大幅に増加 (38.5 → 86.9) し、レイテンシは2倍以上、コストは2倍以上となり、精度は13.6ポイント低下した。40万ドキュメントでは、性能の低下はさらに深刻になる：精度は37.5%まで低下し、平均ツール使用回数は122.4回に増加し、20の例ではツールの最大予算に達した後に処理が終了した。要するに、エージェントが有望なドキュメントに到達すれば、高解像度のインターフェースは依然として強力であるが、候補空間が拡大するにつれて、その最初の有用なアンカーを見つけるためのコストが急激に増加する。

表6：BrowseComp-Plusサブセット（ $n = 100$ ）におけるDCI-Agent-Lite（GPT-5.4 nano）のコンテキスト管理除去実験。「Retained cov.」は、最終的な会話状態に残存するゴールド証拠文書の割合を示す。「Retained cov.」および「Acc.」の括弧内のデルタ値は、L0ベースラインを基準として算出されている。**太字は**、各評価指標の列における最良の結果を示す。

レベル	平均ツール数 ↓	レイテンシ (s) ↓	コスト / q (\$) ↓	保持された証拠文書比率 ↑	精度 ↑
L0	28.54	2226.22	0.0716	26.9	72
L1	29.00	1819.78	0.0720	31.3 (+4.4)	75 (+3)
L2	29.95	4412.73	0.0590	27.2 (+0.3)	69 (-3)
L3	36.89	8711.81	0.1109	27.0 (+0.1)	77 (+5)
L4	35.35	4531.11	0.1021	28.0 (+1.1)	73 (+1)

RQ5: 実行時コンテキスト管理は DCI-Agent-Lite にどのような影響を与えるか？ 最小限のハーネス下で評価を行い、長期的な探索を最も効果的に支援するポリシーを特定することで、実行時コンテキスト管理が DCI に与える影響を分離した。表 1 に記載された 5 つのレベルについて検証を行った。評価には、BrowseComp-Plus の例を 100 件無作為にサンプリングし、アブレーションの結果を表 6 に示した。その傾向は明らかに非単調であり、より積極的な管理が単純に良い結果をもたらすわけではない。L1は最速であり、最終状態で最も多くのゴールド証拠を保持している（31.3）が、L3は保持力バレッジが低い（27.0）にもかかわらず、最高の回答精度（77）を達成している。これは、より多くの証拠をそのまま保持することが、検索を継続するための適切な作業状態を維持することと同義ではないことを示している。一方、L2はコストが最も低いものの、精度は最低（69）であり、L4はL3のピーク後に再び低下する。全体として、最適なバランスが存在する。つまり、選択的に忘却を行うポリシーは、多段階の仮説修正を維持するのに有益である一方、圧縮が弱すぎるとドリフトが生じ、圧縮が強すぎると有用な中間構造が破棄されてしまう。

RQ6：DCI-Agent-Lite において、ツールセットの表現力はどの程度重要か？ この問いは、観察された性能向上が DCI 自体に起因するのか、それとも制限のないシェルなどの表現力の高いツールへのアクセスに起因するのかを検証するものである。表 5 のアブレーション実験は、2 つの側面から答えを示唆している。第一に、その効果は極めて制約の厳しいインターフェース下でもすでに現れている。「read + grep」のみという、ファイルの検査と完全一致またはパターンベースの検索にエージェントを制限した条件下でも、エージェントは BrowseComp-Plus で 61% の精度を達成し、Qwen3-Embedding-8B を使用する検索エージェントのベースライン（45%）を 16 ポイント上回った一方で、ツール呼び出しの頻度はほぼ同等であった。第二に、bash コマンドセットを有効にするとさらに 12 ポイントの向上が見られるが、その代償としてツール使用量、レイテンシ、および計算リソースが大幅に増加する。DCI-Agent-Lite の bash コマンド使用状況の詳細な内訳は [§B.1](#) に記載されている。全体として、これらの結果は、わずかな bash コマンドセットで改善の大部分を引き出すのに十分である一方、表現力を追加すると効率が低下しつつ漸進的な向上が得られることを示している。

5 結論

本論文では、エージェント型検索の代替となる検索パラダイムとして、*直接コーパス相互作用*（DCI）を形式化している。DCI では、エージェントが従来のリトリバーではなく、汎用的な端末ツールを使用して生コーパスを検索・検証する。ランキング指向の情報検索（IR）、マルチホップ QA、エンドツーエンドのエージェント型検索の各ベンチマークにおいて、DCI はオフラインインデックスを一切使用せずに、すでに競争力のあるアプローチとして機能している。制御されたアブレーション実験および軌跡レベルの分析によると、その優位性は検索インターフェースの解決能力に起因していることが示唆される。DCI が成功するのは、多くの場合、ゴールドチェーンをより多く復元するからではなく、抽出された証拠を、より価値の高い局所的な検証、確認、および構成的検索ステップへと変換することで実現されている。これらの結果が、将来の研究において、検索モデル

だけでなく、有能なエージェントが利用できるコーパスインターフェースも評価するきっかけとなることを期待する。

参考文献

Anthropic. Claude Code: エージェント型コーディングツール。 <https://docs.anthropic.com/en/docs/claude-code/overview>, 2025.

Anthropic. Claude Sonnet 4.5の紹介。 <https://www.anthropic.com/news/claude-sonnet-4-5>, 2025.

- Anthropic. AnthropicによるClaude Cowork. <https://www.anthropic.com/product/claude-cowork>, 2026.
- Anthropic. 『Claude Sonnet 4.6 の紹介』。 <https://www.anthropic.com/news/claude-sonnet-4-6>, 2026.
- 浅井明里、ミン・セウォン、鍾澤軒、陳丹琪。「検索ベースの言語モデルとその応用」。 *ACL'23、チュートリアル要旨集*, pp. 41–46、2023年。
- Payal Bajaj, Daniel Campos, Nick Craswell, Li Deng, Jianfeng Gao, Xiaodong Liu, Rangan Ma-jumder, Andrew McNamara, Bhaskar Mitra, Tri Nguyen, et al. Ms marco: 人間が作成した機械読解データセット. *arXiv プレプリント arXiv:1611.09268*, 2016.
- Sebastian Borgeaud, Arthur Mensch, Jordan Hoffmann, Trevor Cai, Eliza Rutherford, Katie Millican, George Bm Van Den Driessche, Jean-Baptiste Lespiau, Bogdan Damoc, Aidan Clark, et al. 「数兆のトークンからの検索による言語モデルの改善」。 *ICML'22*, pp. 2206–2240, 2022.
- Kaiyuan Chen, Yixin Ren, Yang Liu, Xiaobo Hu, Haotong Tian, Tianbao Xie, Fangfu Liu, Haoye Zhang, Hongzhang Liu, Yuan Gong, et al. xbench: 職業に即した実世界評価を用いたエージェントの生産性スケーリングの追跡. *arXiv プレプリント arXiv:2506.13651*, 2025a.
- Zijian Chen, Xueguang Ma, Shengyao Zhuang, Ping Nie, Kai Zou, Andrew Liu, Joshua Green, Kshama Patel, Ruoxi Meng, Mingyi Su, Sahel Sharifmoghadam, Yanxi Li, Haoran Hong, Xinyu Shi, Xuye Liu, Nandan Thakur, Crystina Zhang, Luyu Gao, Wenhui Chen, および Jimmy Lin. Browsecomp-plus: デイリーリサーチエージェントのための、より公平かつ透明性の高い評価ベンチマーク. *arXiv プレプリント arXiv:2508.06600*, 2025b.
- Xiang Deng, Jeff Da, Edwin Pan, Yannis Yiming He, Charles Ide, Kanak Garg, Niklas Lauffer, Andrew Park, Nitin Pasari, Chetan Rane, et al. Swe-bench pro: AIエージェントは長期的なソフトウェア工学タスクを解決できるか? *arXiv プレプリント arXiv:2509.16941*, 2025.
- Jiaxuan Gao, Wei Fu, Mingyang Xie, Shusheng Xu, Chuyi He, Zhiyu Mei, Banghua Zhu, および Yi Wu. 「10ターンを超えて：大規模非同期強化学習による長期的なエージェント探索の実現」。 *arXiv プレプリント arXiv:2508.07976*, 2025年。
- Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, および Haofen Wang. 大規模言語モデルにおける検索強化生成：調査. *arXiv プレプリント arXiv:2312.10997*, 2023.
- Paul Gauthier. Aider：ターミナル上で実現するAIペアプログラミング。 <https://github.com/Aider-AI/aider>, 2024.
- GNUプロジェクト. Pipelines. https://www.gnu.org/software/bash/manual/html_node/Pipelines.html, 2025.
- Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat, および Mingwei Chang. 「検索拡張言語モデルの事前学習」。 *ICML'20*, pp. 3929–3938, 2020.
- Xanh Ho, Anh-Khoa Duong Nguyen, Saku Sugawara, および Akiko Aizawa. 「推論ステップの包括的評価のためのマルチホップQAデータセットの構築」。 *COLING'20*, pp. 6609–6625, 2020年。
- Gautier Izacard, Mathilde Caron, Lucas Hosseini, Sebastian Riedel, Piotr Bojanowski, Armand Joulin, および Edouard Grave. 対比学習を用いた教師なし高密度情報検索. *TMLR*, 2022.
- Soyeong Jeong, Jinheon Baek, Sukmin Cho, Sung Ju Hwang, および Jong C Park. Adaptive-rag: 質問の複雑度に応じた検索拡張型大規模言語モデルの適応学習. *NAACL-HLT'24*, pp. 7036–7050, 2024.
- Dongfu Jiang, Yi Lu, Zhuofeng Li, Zhiheng Lyu, Ping Nie, Haozhe Wang, Alex Su, Hui Chen, Kai Zou, Chao Du, 他. Verltool：ツールの使用を伴う総合的なエージェント型強化学習に向けて. *arXiv プレプリント arXiv:2509.01055*, 2025年。

- Carlos E. Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, および Karthik Narasimhan. SWE-bench: 言語モデルは現実世界のGitHubの課題を解決できるか? *ICLR'24*収録, 2024年。
- Bowen Jin, Hansi Zeng, Zhenrui Yue, Jinsung Yoon, Sercan O Arik, Dong Wang, Hamed Zamani, および Jiawei Han. Search-r1: 強化学習を用いてLLMに推論能力と検索エンジンの活用能力を習得させる。 *COLM'25*, 2025年。
- マンダル・ジョシ、ウンソル・チェ、ダニエル・S・ウェルド、およびルーク・ゼトルモイヤー。「Triviaqa: 読解問題向けの大規模遠隔教師ありチャレンジデータセット」。 *ACL'17*, pp. 1601–1611, 2017年。
- Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, および Wen-tau Yih. オープンドメインの質問応答のための高密度パッセージ検索. *EMNLP'20*, pp. 6769–6781, 2020.
- オマール・ハッタブ、マテイ・ザハリア。「Colbert: BERTを用いた文脈に応じた後期相互作用による効率的かつ効果的なパッセージ検索」。 *SIGIR'20*, pp. 39–48, 2020年。
- Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, Michael Collins, Ankur Parikh, Chris Alberti, Danielle Epstein, Illia Polosukhin, Jacob Devlin, Kenton Lee, 他。Natural Questions: 質問応答研究のためのベンチマーク。 *TACL*, 7:453–466, 2019.
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. 知識集約型NLPタスクのための検索強化生成. *NeurIPS'20*, pp. 9459–9474, 2020.
- Xiangyi Li, Wenbo Chen, Yimin Liu, Shenghan Zheng, Xiaokun Chen, Yifeng He, Yubo Li, Bingran You, Haotian Shen, Jiankai Sun, 他. Skillsbench: 多様なタスクにおけるエージェントスキルの性能を評価するベンチマーク. *arXiv プレプリント arXiv:2602.12670*, 2026a.
- Li Zehan, Zhang Xin, Zhang Yanzhao, Long Dingkun, Xie Pengjun, および Zhang Meishan. 多段階対比学習による汎用テキスト埋め込みの実現に向けて. *arXiv プレプリント arXiv:2308.03281*, 2023.
- Zhuofeng Li, Haoxiang Zhang, Seungju Han, Sheng Liu, Jianwen Xie, Yu Zhang, Yejin Choi, James Zou, および Pan Lu. 効果的な計画立案と道具使用のためのフロー内エージェント型システム最適化. *arXiv プレプリント arXiv:2510.05592*, 2025.
- Zhuofeng Li, Dongfu Jiang, Xueguang Ma, Haoxiang Zhang, Ping Nie, Yuyu Zhang, Kai Zou, Jianwen Xie, Yu Zhang, および Wenhui Chen. Openresearcher: 長期的な深層研究軌跡合成のための完全オープンなパイプライン. *arXiv プレプリント arXiv:2603.20278*, 2026b.
- Jiawei Liu, Chunqiu Steven Xia, Yuyao Wang, および Lingming Zhang. 「ChatGPTで生成されたコードは本当に正しいのか? コード生成における大規模言語モデルの厳密な評価」。 *NeurIPS'23*, pp. 21558–21572, 2023.
- Wenhan Liu, Xinyu Ma, Weiwei Sun, Yutao Zhu, Yuchen Li, Dawei Yin, および Zhicheng Dou. Reason-rank: 強力な推論能力によるパッセージランキングの強化. *arXiv プレプリント arXiv:2508.07050*, 2025.
- Mike A Merrill, Alexander G Shaw, Nicholas Carlini, Boxuan Li, Harsh Raj, Ivan Bercovich, Lin Shi, Jeong Yeon Shin, Thomas Walshe, E Kelly Buchanan, et al. Terminal-bench: コマンドラインインターフェースにおける困難で現実的なタスクに対するエージェントのベンチマーク. *arXiv プレプリント arXiv:2601.11868*, 2026.
- グレゴワール・ミアロン、クレマンティーヌ・フーリエ、トーマス・ウルフ、ヤン・ルカン、トーマス・シアロム。Gaia: 汎用AIアシスタントのためのベンチマーク。 *ICLR'24*収録, 2024年。
- OpenAI. text-embedding-3-large. <https://developers.openai.com/api/docs/models/text-embedding-3-large>, 2024.

OpenAI. APIにおけるGPT-4.1の導入. <https://openai.com/index/gpt-4-1/>, 2025a. OpenAI. GPT-5の導入.
<https://openai.com/index/introducing-gpt-5/>, 2025b.

OpenAI. GPT-5.2の提供開始。 <https://openai.com/zh-Hans-CN/index/introducing-gpt-5-2/>, 2025c.

OpenAI. 「OpenAI O3 および O4-mini の紹介」 。 <https://openai.com/index/introducing-o3-and-o4-mini/>, 2025d.

OpenAI. GPT-5.4の発表。 <https://openai.com/index/introducing-gpt-5-4/>、2026年。 OpenAI. GPT-5.4 nanoモデル。 <https://developers.openai.com/api/docs/models/gpt-5.4-nano>, 2026年。

Guilherme Penedo, Hynek Kydlic'ek, Anton Lozhkov, Margaret Mitchell, Colin A Raffel, Leandro Von Werra, Thomas Wolf 他. 「The fineweb datasets: Decanting the web for the finest text data at scale」 。 *NeurIPS'24*, pp. 30811–30849, 2024年。

Ofir Press, Muru Zhang, Sewon Min, Ludwig Schmidt, Noah A Smith, および Mike Lewis. 言語モデルにおける構成性のギャップの測定と縮小. 『*Findings of EMNLP'23*』, pp. 5687–5711, 2023.

Ori Ram, Yoav Levine, Itay Dalmedigos, Dor Muhlgay, Amnon Shashua, Kevin Leyton-Brown, および Yoav Shoham. 「文脈内検索による拡張言語モデル」 。 *TACL*, 11:1316–1331, 2023年。

Stephen Edward Robertson, Steve Walker, Susan Jones, Micheline M Hancock-Beaulieu, Mike Gatford, et al. 「TRECにおけるOkapi」 . *TREC'94*, 1994.

Weijia Shi, Sewon Min, Michihiro Yasunaga, Minjoon Seo, Richard James, Mike Lewis, Luke Zettlemoyer, および Wentau Yih. Replug: 検索拡張型ブラックボックス言語モデル. *NAACL-HLT'24*, pp. 8371–8384, 2024.

Aditi Singh, Abul Ehtesham, Saket Kumar, および Tala Talaei Khoei. 「Agentic retrieval-augmented generation: A survey on agentic rag」 。 *arXiv プレプリント arXiv:2501.09136*, 2025年。

Huatong Song, Jinhao Jiang, Yingqian Min, Jie Chen, Zhipeng Chen, Wayne Xin Zhao, Lei Fang, および Ji-Rong Wen. R1-searcher：強化学習によるLLMの検索能力の促進. *arXiv プレプリント arXiv:2503.05592*, 2025.

Peter Steinberger および OpenClaw 貢献者たち. OpenClaw: あなたのパーソナルAIアシスタント. <https://github.com/openclaw/openclaw>, 2025.

Hongjin Su, Howard Yen, Mengzhou Xia, Weijia Shi, Niklas Muennighoff, Han yu Wang, Liu Haisu, Quan Shi, Zachary S Siegel, Michael Tang, Ruoxi Sun, Jinsung Yoon, Serkan O Arik, Danqi Chen, および Tao Yu. BRIGHT: 推論を多用する検索のための現実的で挑戦的なベンチマーク. *ICLR'25* 収録, 2025.

シュレヤス・スブラマニアン、アデワレ・アキンファデリン、ヤンヤン・チャン、イシャン・シン、マニ・カヌジャ、サンディーブ・シン、およびマイラ・ラデイラ・タンケ。「キーワード検索だけで十分：エージェントによるツール活用を用いて、ベクトルデータベースなしでRAGレベルの性能を達成する」 。 *arXiv プレプリント arXiv:2602.23368*, 2025.

Hao Sun, Zile Qiao, Jiayan Guo, Xuanbo Fan, Yingyan Hou, Yong Jiang, Pengjun Xie, Yan Zhang, Fei Huang, および Jingren Zhou. 「Zerosearch：検索を行わずにLLMの検索能力を促進する」 。 *arXiv プレプリント arXiv:2505.04588*, 2025年。

Weiwei Sun, Lingyong Yan, Xinyu Ma, Shuaiqiang Wang, Pengjie Ren, Zhumin Chen, Dawei Yin, および Zhaochun Ren. 「ChatGPTは検索が得意か？ 再ランク付けエージェントとしての大規模言語モデルの検証」 . *EMNLP'23*, pp. 14918–14937, 2023.

Lintang Sutawika, Aditya Bharat Soni, Apurva Gandhi, Taha Yassine, Sanidhya Vijayvargiya, Yuchen Li, Xuhui Zhou, Yilin Zhang, Leander Melroy Maben, Graham Neubig, et al. Codescout: コード検索エージェントの強化学習のための効果的なレシピ. *arXiv プレプリント arXiv:2603.17829*, 2026.

MiroMind Team、Song Bai、Lidong Bing、Carson Chen、Guanzheng Chen、Yuntao Chen、Zhe Chen、Ziyi Chen、Xuan Dong 他。Mirothinker：モデル、コンテキスト、およびインタラクティブなスケーリングを通じて、オープンソースの研究エージェントの性能の限界を押し広げる。*arXiv プレプリント arXiv:2511.11793*、2025a。

- Tongyi DeepResearchチーム、Baixuan Li、Bo Zhang、Dingchu Zhang、Fei Huang、Guangyu Li、Guoxin Chen、Huifeng Yin、Jialong Wu、Jingren Zhouほか。Tongyi deepresearch技術報告書。arXiv プレプリント *arXiv:2510.24701*, 2025b。
- ナンダン・タクール、ニルス・ライマーズ、アンドレアス・リュックレ、アビシエク・スリヴァスタヴァ、イリーナ・グレヴィッチ。BEIR: 情報検索モデルのゼロショット評価のための異種ベンチマーク。 *NeurIPS'21, Datasets and Benchmarks*, 2021.
- Harsh Trivedi、Niranjan Balasubramanian、Tushar Khot、および Ashish Sabharwal。「Musique：シングルホップ質問構成によるマルチホップ質問」。 *TACL*, 10:539–554、2022年。
- Ellen M Voorhees および Dawn M Tice. 質問応答テストコレクションの構築。 *SIGIR'00*, pp. 200–207, 2000.
- ヘニング・ワックスムート、シャバズ・サイード、およびベノ・シュタイン。「事前のトピック知識なしでの最適な反論の検索」。 *ACL'18*, pp. 241–251、2018年。
- David Wadden, Shanchuan Lin, Kyle Lo, Lucy Lu Wang, Madeleine van Zuylen, Arman Cohan, および Hannaneh Hajishirzi。「事実か虚構か：科学的主張の検証」。 *EMNLP'20*, pp. 7534–7550、2020年。
- Liang Wang、Nan Yang、Xiaolong Huang、Binxing Jiao、Linjun Yang、Daxin Jiang、Rangan Majumder、および Furu Wei。「弱教師あり対比事前学習によるテキスト埋め込み」。 *arXiv プレプリント arXiv:2212.03533*, 2022年。
- Xingyao Wang, Boxuan Li, Yufan Song, Frank F. Xu, Xiangru Tang, Mingchen Zhuge, Jiayi Pan, Yueqi Song, Bowen Li, Jaskirat Singh, Hoang H. Tran, Fuqiang Li, Ren Ma, Mingzhang Zheng, Bill Qian, Yanjun Shao, Niklas Muennighoff, Ziyi Yang, および Graham Neubig. OpenHands: ジェネラリストエージェントとしてのAIソフトウェア開発者向けオープンプラットフォーム。 *ICLR'25*, 2025.
- Jason Wei、Zhiqing Sun、Spencer Papay、Scott McKinney、Jeffrey Han、Isa Fulford、Hyung Won Chung、Alex Tachard Passos、William Fedus、および Amelia Glaese。Browsecomp：ブラウジングエージェントのためのシンプルでありながら挑戦的なベンチマーク。 *arXiv プレプリント arXiv:2504.12516*, 2025年。
- Orion Weller、Kathryn Ricci、Eugene Yang、Andrew Yates、Dawn Lawrie、および Benjamin Van Durme。「Rank1：情報検索における再ランク付けのためのテスト時計算」。 *COLM'25*, 2025年。
- Chunqiu Steven Xia、Yinlin Deng、Soren Dunn、および Lingming Zhang。「LLMベースのソフトウェアエンジニアリングエージェントの謎を解き明かす」。『*ACMソフトウェアエンジニアリング論文集*』、2(FSE):801–824、2025年。
- John Yang、Carlos E Jimenez、Alexander Wettig、Kilian Lieret、Shunyu Yao、Karthik Narasimhan、および Ofir Press。「Swe-agent：エージェント・コンピュータ・インターフェースによる自動ソフトウェア工学の実現」。 *NeurIPS'24*, pp. 50528–50652、2024年。
- Zhilin Yang、Peng Qi、Saizheng Zhang、Yoshua Bengio、William Cohen、Ruslan Salakhutdinov、および Christopher D Manning。Hotpotqa: 多様で説明可能なマルチホップ質問応答のためのデータセット。 *EMNLP'18*, pp. 2369–2380, 2018.
- Qiyang Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Lingjun Liu, et al. Dapo: 大規模なオープンソースLLM強化学習システム。 *arXiv プレプリント arXiv:2503.14476*, 2025.
- Z.AI. Glm-4.7: コーディング能力の向上。 <https://z.ai/blog/glm-4.7>, 2025.
- Mario Zechner および Pi 貢献者たち。Pi: 最小限のターミナルコーディング・ハーネス。 <https://shittycodingagent.ai>, 2026.

ChengXiang Zhai. 汎用人工知能のための情報検索：情報検索研究の新たな視点。 *SIGIR '25*, pp. 3876–3886、2025年。

Weinan Zhang, Junwei Liao, Ning Li, Kounianhua Du, および Jianghao Lin. 「エージェント型情報検索」。 *arXiv プレプリント arXiv:2410.09713*, 2024年。

Yanzhao Zhang, Mingxin Li, Dingkun Long, Xin Zhang, Huan Lin, Baosong Yang, Pengjun Xie, An Yang, Dayiheng Liu, Junyang Lin, et al. 「Qwen3 embedding：基盤モデルを通じたテキスト埋め込みと再ランク付けの進展」。 *arXiv プレプリント arXiv:2506.05176*, 2025.

Shengyao Zhuang, Xueguang Ma, Bevan Koopman, Jimmy Lin, および Guido Zuccon. Rank-r1: 強化学習を用いたLLMベースの文書再ランク付けにおける推論能力の向上. *arXiv プレプリント arXiv:2503.06034*, 2025.

目次

A 実験の詳細	18
A.1 ベンチマーク	18
A.2 比較対象のベースライン	19
A.3 評価指標	20
B 実験結果に関するさらなる考察	21
B.1 DCI-Agent-Liteの検索パターンの詳細な分析	21
C 指示テンプレート	22
C.1 QAの指示	22
C.2 IRに関する説明	22
C.3 裁判官としてのLLM	23
D 事例研究	24
D.1 事例1：実証例	24
D.2 事例 2a：エージェント型検索における DCI-Agent-CC	26
D.3 事例 2b：エージェント型検索における DCI-Agent-Lite の適用	29
D.4 事例 3a：知識集約型QAにおけるDCI-Agent-CCの適用	32
D.5 事例 3b：知識集約型QAにおけるDCI-Agent-Liteの適用	33
D.6 事例 4a：情報検索における DCI-Agent-CC の適用	35
D.7 事例 4b：情報検索における DCI-Agent-Lite の適用	38
D.8 事例 5a：エージェント型検索における DCI-Agent-CC の失敗事例	40
D.9 事例 5b：エージェント型検索における DCI-Agent-Lite の失敗事例	49

付録

A 実験の詳細

A.1 ベンチマーク

BRIGHT（生物学、地球科学、経済学、ロボット工学）およびBamboogleについては、テストセット全体を用いて評価を行う。その他のデータセットについては、効率性を考慮し、データセットごとに50例のランダムなサンプルを用いて評価を行う。

エージェント型検索

- **BrowseComp-Plus** (Chen et al., 2025b) は、深層研究エージェントの制御された評価を目的として設計されたクローズドコーパスベンチマークである。本ベンチマークは、人間によって検証された補足文書と抽出されたハードネガティブを含む、固定された慎重にキュレーションされたコーパスを採用しており、公平かつ透明性の高い実験を可能にする。このベンチマークは、BrowseComp (Wei et al., 2025) のクエリのサブセットから導出された、複雑で高度な研究課題で構成されており、コーパス内の複数の文書から証拠を検索・統合する必要があるため、深層検索およびマルチホップ推論能力の評価に最適である。埋め込みベースの検索ベースラインについては、公式に公開されたコーパスとBM25/Qwen3-Embedding-8B FAISSインデックスを組み合わせ、オフライン検索エンジンを構築し、ライブWebアクセスへの依存を排除した。DCIについては、エージェントはインデックスを使用せずにターミナルツールを介して同じコーパスにアクセスする。

知識集約型QA

- **NQ** (Kwiatkowski et al., 2019) は、実際の Google 検索クエリから導出され、証拠としてウィキペディアの文章がペアリングされた、大規模なオープンドメイン QA ベンチマークである。主にシングルホップの事実検索を評価する。
- **TriviaQA** (Joshi et al., 2017) は、愛好家によって作成された雑学クイズを含み、証拠はウィキペディアやウェブから収集されており、多様で自然発生的な質問下でのシングルホップ検索を評価する。
- **Bamboogle** (Press et al., 2023) は、正確に2つの推論ステップを必要とすることで近道的な回答を防ぐよう設計された、手作業で構築されたマルチホップデータセットである。各質問は、少なくとも2つの文書からの証拠を組み合わせなければ回答できない。
- **HotpotQA** (Yang et al., 2018) は、Wikipedia から構築された広く利用されているマルチホップベンチマークであり、2つの裏付け文書にわたる推論を必要とするブリッジ問題や比較問題を特徴としています。
- **2WikiMultiHopQA** (Ho et al., 2020) は、構造化されたウィキデータ (Wikidata) の知識と非構造化されたウィキペディアのテキストを組み合わせたマルチホップQAデータセットであり、相互に関連する事実間での解釈可能な逐次推論を支援するために、注釈付きの推論チェーンを提供している。
- **MuSiQue** (Trivedi et al., 2022) は、シングルホップの質問を多段階の連鎖に組み合わせて構築された難易度の高いマルチホップ推論ベンチマークであり、各推論ステップは前のステップから導き出された情報に依存している。これは推論の近道を最小限に抑えるように設計されており、真の逐次推論が求められる。

コーパスの収集以降に正解が変更されている可能性がある曖昧な質問や、時間的制約のある事例は除外しています。

IRランキング

- **BRIGHT** (Su et al., 2025) は、推論を多用する検索ベンチマークであり、クエリには表面的なキーワードの重複を超えた、非自明なドメイン推論が求められる。我々は、生物学（103件のクエリ）、地球科学（116件の

クエリ)、経済学(103件のクエリ)、ロボット工学(101件のクエリ)という、異なる科学分野にまたがる4つのBRIGHTデータセットを評価した。

- **BEIR** ([Thakur et al., 2021](#)) は、多様な分野とタスクを網羅する異種混合IRベンチマークである。我々は、2つのBEIRデータセットを評価した。1つは反論検索タスクであるArguAna ([Wachsmuth et al., 2018](#)) (1,406件のクエリ; うち50件をサンプリング)、もう1つは、ある主張を支持または反駁する抄録を検索する科学的事実検証タスクであるSciFact ([Wadden et al., 2020](#)) (300件のクエリ; うち50件をサンプリング) である。

表7は、すべてのベンチマークで使用された検索コーパスをまとめたものである。

表7：検索コーパスの統計。Avg. len. は、空白で区切られた単語数で測定した文書の平均長である。

コーパス	使用された	文書数	平均長さ (単語)
BrowseComp-Plus	BrowseComp-Plus	100,195	5,179
BRIGHT-Biology	BRIGHT-Biology	57,359	48
BRIGHT-地球科学	BRIGHT-地球科学	121,249	28
BRIGHT-経済学	BRIGHT-経済学	50,220	52
BRIGHT-Robotics	BRIGHT-Robotics	61,961	25
Wikipedia-18	NQ、TriviaQA、Bamboogle、 HotpotQA、2WikiMQA、MuSiQue	21,015,324	100
BEIR-ArguAna	BEIR-ArguAna	8,674	167
BEIR-SciFact	BEIR-SciFact	5,183	214

A.2 比較対象のベースライン

および独自モデル

以下の独自モデルは、BrowseComp-Plusのベースライン評価においてエージェントのバックボーンとして機能します。

- **OpenAIシリーズ** (OpenAI) : o3 (OpenAI, 2025d)、GPT-5.2 (OpenAI, 2025c)、およびGPT-5.4 nano (OpenAI, 2026)。我々の実験において、o3はすべてのベースラインエージェントの中で、BrowseComp-Plusにおいて最も優れた検索機能強化パフォーマンスを発揮した。GPT-5.2は標準的な検索エージェントのバックボーンとして機能する。GPT-5.4 nanoは、すべての包括的評価および制御されたアブレーション実験において、DCI-Agent-Liteのバックボーンとして使用される軽量モデルである。
- **Claude 4シリーズ** (Anthropic) : Claude Sonnet 4.6 (Anthropic, 2026)、Claude Sonnet 4.5 (Anthropic, 2025)、およびClaude Haiku 4.5。各モデルはBrowseComp-Plus上でリトリートエージェントのバックボーンとして評価されており、さらにClaude Sonnet 4.6は、すべての評価においてDCI-Agent-CCの主要なバックボーンとして機能している。
- **GLM シリーズ** (Z.AI): GLM-4.7 (Z.AI, 2025)。BrowseComp-Plus において、検索エージェントのバックボーンとして評価された最先端モデル。
- **Kimiシリーズ** (Moonshot AI) : BrowseComp-Plusにおいてリトリートエージェントのバックボーンとして評価された最先端モデルであるKimi K2。

リトリートエージェント

- **R1-Searcher-7B** (Song et al., 2025) : プロセス報酬やディステーションを必要とせず、2段階の結果監督型強化学習 (RL) フレームワークを通じて、LLMが外部検索システムを呼び出せるようにするオープンウェイトエージェント。ベースモデルと指示チューニングモデルの両方に対応している。
- **Search-R1-32B** (Jin et al., 2025) : 強化学習を通じて推論と検索を交互に実行するオープンウェイトエージェント。
- **ZeroSearch-7B** (Sun et al., 2025) : トレーニング中に実際の検索エンジンを使用せずに検索を行うよう訓練されたオープンウェイトエージェント。SFTを用いて検索をシミュレートし、推論能力を強化するために文書の品質を低下させるカリキュラムを採用している。
- **Verl-Tool-Search-7B-DAPO** (Jiang et al., 2025) : ツール使用強化学習のための統一フレームワークに基づいて構築されたオープンウェイトエージェントであり、非同期ロールアウトと標準化されたツールAPIを介してマルチターンかつステートフルな相互作用をサポートする。DAPO (Yu et al., 2025)を用いて学習されている。
- **ASearcher-Local-14B** (Gao et al., 2025) : 完全に非同期な強化学習 (RL) を用いて学習されたオープンウェイト

ト型ディープリサーチエージェント。軌跡の収集とモデル学習を分離しており、最大128ターンまでの相互作用を可能にする。

スパースおよびデンストリトリバル

- **BM25** (Robertson et al., 1994)：語彙マッチングと用語頻度重み付けに基づく古典的なスパース手法。情報検索（IR）ランキングにおける標準的なスパース検索ベースラインとして、またBrowseComp-Plusにおける検索エージェントの2つの検索エンジンの1つとして使用される。

- **OpenAI text-embedding-3-large** (OpenAI, 2024)：事前構築されたインデックスに対する最近傍検索によって評価された、独自の密な埋め込みモデル。BRIGHTおよびBEIRにおいて、強力な密な検索のベースラインとして機能する。
- **GTE-Qwen2-7B-Instruct** (Li et al., 2023)：Qwen2を基盤とするGTEファミリーのオープンウェイト高密度埋め込みモデルであり、IRランキングベンチマークにおける最近傍検索を通じて評価されている。
- **E5** (Wang et al., 2022)：オープンウェイトの密埋め込みモデル。知識集約型QAタスクにおける検索エージェントのベースラインの主要な検索エンジンとして機能する。
- **Qwen3-Embedding-8B** (Zhang et al., 2025)：Qwen3ファミリーに属するオープンウェイト埋め込みモデル。BrowseComp-Plusにおける検索エージェントのベースラインにおいて、主要な高密度検索エンジンとして機能する。
- **Rank-R1-14B** (Zhuang et al., 2025)：クエリおよび候補文書に対して明示的な推論を行うオープンウェイトの再ランク付けモデルであり、少数の関連性ラベルのみを用い、推論に関する監督なしに強化学習（RL）によって訓練されている。
- **Rank1-32B** (Weller et al., 2025)：大規模推論モデル（例：DeepSeek-R1）からの推論トレースを、MS MARCOで学習されたより小規模なモデルに蒸留することでテスト時の計算を適用するオープンウェイト再ランク付けモデルであり、関連性判定の前に説明可能な推論チェーンを生成する。
- **ReasonRank-32B** (Liu et al., 2025)：自動推論特化型データ合成パイプラインを用い、2段階（推論パターンの学習のためのSFT、続いてマルチビューランキング報酬を用いたRL）で学習された、推論集約型のリストワイズ再ランク付けモデル。

A.3 評価指標

精度評価指標 Browsecomp-Plusおよび知識集約型QAについては、最終回答の正しさを評価するために、GPT-4.1 (OpenAI, 2025a) をLLMベースの判定者として使用する。判定者は、予測された回答と参照回答のみを比較する。参照回答は短く明確に定義されているため、比較は概ね曖昧がなく、意味的および数値的な等価性を確実に捉えることができる。具体的な判定プロンプトについては、§C.3で詳述する。IRランキングベンチマークについては、先行研究 (Voorhees & Tice, 2000; Bajaj et al., 2016; Thakur et al., 2021; Su et al., 2025) に倣い、NDCG@10を主要な評価指標として用いる。

解像度指標 §3.3の解像度指標は、観測レベルの候補集合 $R(o_t) = \{(d_{t,1}, \sigma_{t,1}), \dots, (d_{t,n_t}, \sigma_{t,n_t})\}$ に対して適用される。このセクションでは、各インターフェースに対して、 $R(o_t)$ 、スニペット $\sigma_{t,i}$ 、ひいてはスニペットの長さ $\ell_{t,i} = |\sigma_{t,i}|$ がどのように具体化されるかを規定する。

リトリバーを介したアクセスでは、マッピングは直接的です。つまり、返された各結果が1つの候補 $(d_{t,i}, \sigma_{t,i})$ となり、ここで $d_{t,i}$ は検索されたドキュメント、 $\sigma_{t,i}$ はリトリバーによって返されたプレビューテキストです。したがって、トップ k 検索の呼び出しの場合、 $n_t = k$ となり、 ℓ_t は単にプレビューの長さのリストとなります。

DCIトレースの場合、 $R(o_t)_{i \neq k}$ 、インターフェースによって明示的に提供されるのではなく、ツールの生出力から再構築されなければならない。評価者はまず、明示的なファイルパス、あるいは d^* にマッピングできる一致したローカルテキストを通じて、各観測値を表面化したゴールド文書 $d^* \in D^*(q)$ に照合します。次に、ツールの種類に応じて、スニペットを保守的に割り当てます。

- **grep/rgスタイルの検索**。アラインメントされた各一致行は、1つの候補 $(d_{t,i}, \sigma_{t,i})$ を生成し、 $\sigma_{t,i}$ はその一致行に等しくなる。ある観測値に、同じゴールド文書からの複数のアラインメントされた行が含まれている場合、それらはすべて $R(o_t)$ に属し、§3.3のメトリックは、 $H(d^*, \tau)$ に対する最大化を通じて、それらのうち

最良の seg-score を後で保持することになる。

- **読み取り方式によるファイル検査。** ツールがゴールドドキュメントファイルを読み取り、返されたテキストがアノテーションされたゴールドエビデンスと十分に一致する場合、抽出された読み取りスパンが $\sigma_{t,i}$ として使用される。
- **パス限定の抽出または一致しないローカルテキスト。** 一部の観測では、信頼性の高いローカルテキストスパンを特定せずに、パス、リスト、またはその他のメタデータを通じてゴールドドキュメントが抽出されることがある。 その場合、その観測結果は d^* を「抽出済み」としてマークすることでカバレッジに寄与するが、 $\ell_{t,i} = |d^*|$ と設定し、位置特定目的において $\sigma_{t,i}$ を全文スニペットとして同等に扱う。これにより、有用な証拠の位置特定がないまま文書に到達したことを反映して、低い seg-score が算出される。

このフォールバックルールが特に重要となるのはDCIの場合であり、これはツールによって証拠の公開粒度が大きく異なるためである。対照的に、リトリーバーを介したアクセスでは、リトリーバーAPIを通じて $R(o_i)$ と $\sigma_{t,i}$ の両方がすでに標準化されている。




図6：100件のケース（合計3,168コマンド）におけるDCI-Agent-Liteの軌跡上のBashコマンドパターンの分布。この比率は、正解および不正解の実行の両方におけるコマンドの使用状況を統合したものであり、エージェントが主にrg | headやrg | rgといった構成的検索演算子に依存しており、文書全体の読み込みはごくまれにしか行われていないことを示している。

B 実験結果に関するさらなる考察

B.1 DCI-Agent-Liteの検索パターンの詳細分析

DCIエージェントがツールの使用をどのように配分しているかをより深く理解するため、図6ではBashの操作を代表的なコマンドパターンに分類している。Bashの使用は、検索と制限を組み合わせた操作（rg | head、56.2%）および連鎖検索（rg | rg、20.6%）が大部分を占めており、集計やカウント（wc、7.8%）、単一キーワード検索（rg keyword、6.3%）、ディレクトリ一覧表示（ls、4.3%）に割り当てられる割合は小さい。Pythonスクリプトの実行（python -c、2.4%）やファイルの特定（find / ls | rg、2.1%）はごくまれにしか見られず、ドキュメント全体の読み込み（cat、0.1%）はほぼ使用されていません。残りの0.2%はその他のコマンドに分類されます。全体として、この分布は、エージェントがBashを高解像度の検索インターフェースとして扱っていることを示唆している。すなわち、エージェントは語彙フィルタを構成し、範囲が限定されたローカルなスニペットのみを検査し、文書全体を広く読み込むのではなく、反復的な完全一致検証を通じて候補の範囲を絞り込んでいる。

これらのコマンドトレースに基づき、ツール呼び出しの挙動を、おおむね時系列順に従って、6つの代表的な操作パターンにさらに分類した。(1) コーパス探索：ディレクトリ構造をスキャンして、コーパス内の関連性のある可能性のある領域を特定する（例：lsを使用）。(2) 広範囲なキーワード検索：コーパスレベルでのパターンマッチングを行い、候補となるファイルやスニペットを抽出する（例：rg -n）。(3) 反復的な絞り込み：検索クエリを段階的に精緻化し、検索範囲を絞り込む（例：rg -n "keyword1" | rg "keyword2" のように、より具体的な rg パターンを連鎖させる）；(4) 対象文書の閲覧：有望と特定された特定のファイルを精査する（例：read や cat）；(5) 文書内詳細検索：複数のキーワードや局所的な検索を用いて、単一の文書内を詳細に調査する（例：rg -n "term" file.txt）；および(6) 文書間比較：検証、曖昧性の解消、または分析のために、複数の文書を交互に参照する（例：rg -n "keyword" file1.txt file2.txt）。

C 操作テンプレート

C.1 QA 指示

DCI-Agent プロンプト

あなたは几帳面な研究助手です。以下の質問に答える際は、@corpus内のドキュメントのみを使用してください。オンライン検索や、ripgrepおよびBash以外の外部ツールは使用しないでください。

質問：query

検索戦略（厳守）：

1. ripgrep/Bash を使用して直接検索してください。Agent ツールの使用、サブエージェントの起動、ウェブの閲覧は行わないでください。
2. 時間を節約するため、1つの回答内で複数のripgrep/Bash検索を並列で実行してください。
3. 結論を出す前に、リコールを最大化するため、多様度的を絞ったキーワードを使用してください。

指示：

- 複数の関連キーワードの組み合わせを用いて、@corpus を徹底的に検索してください。
- 1つの回答を確定する前に、競合する候補を特定し、除外してください。
- 裏付けとなるすべての発見については、文書のパス（例：[@corpus/relative_path]）を使用して本文中に引用してください。

回答は、必ず以下の形式に厳密に従ってください：

説明：{{段階的な推論とインライン引用（例：[@corpus/relative_path]）}}

正確な回答：{{簡潔な最終回答のみ}}

確信度：{{0～100%；証拠が不十分、曖昧、または欠落している場合は50%未満を使用}}

C.2 IRに関する説明

DCI-Agentのプロンプ

あなたは几帳面な研究助手です。以下の質問に答える際は、@corpus内の文書のみを使用してください。オンライン検索や、GrepおよびBash以外の外部ツールは使用しないでください。

質問：query

検索および情報抽出は、以下に指定された戦略と基準に従わなければなりません：

検索戦略（厳守）：

1. Grep/Bashのみを使用すること — Agentツールの使用、サブエージェントの起動、ウェブの閲覧は行わないこと。
2. 時間を節約するため、1つのレスポンス内で複数のGrep/Bash検索を並列で実行してください。
3. 結論を出す前に、リコール率を最大化できるよう、多様な絞ったキーワードを使用してください。
4. 各ラウンド終了後、不足している点を振り返り、見落とした角度をカバーするための追跡検索を実行してください。
5. 数件の文書が見つかっただけで検索を中止せず、考えられるすべての検索角度を徹底的に網羅すること。

検索に関する指示：

- リコール率と精度のどちらも等しく重要です。出力結果はNDCGで評価され、関連する文書を見逃すことも、無関係な文書を含めることもペナルティの対象となります。
- 真に関連性のある文書はすべて見つけ出してください。重要な文書を見逃すと、再現率が低下します。
- 候補となる各文書を慎重に読み、その上で含めるかどうかを判断してください。無関係な文書を含めると、精度が低下します。
- 文書が関連性を持つのは、その文書が質問に直接答えているか、答えを裏付ける重要な証拠を提供している場合に限られます。
- 本題から外れた文書や、間接的にしか関連しない文書は含めないでください。

ランク付けに関する指示：

- 最終リストを関連性順にランク付けしてください。質問への回答に最も直接的に役立つ文書を1位にします。
- ランク付けの質はNDCGスコアに影響します。

回答は、以下の形式に厳密に従う必要があります：

関連文書（関連性の高い順にランク付け、最も関連性の高いものを最初に；最大20件）：

1. corpus/doc1.txtへのパス
2. corpus/doc2.txtへのパス
3. corpus/doc3.txtへのパス

（作業ディレクトリからの完全な相対パスを使用してください。最大20件まで記載し、直接関連性のない文書は省略してください）

説明：{{インライン引用（例：[corpus/relative_path]）を伴う段階的な推論}}

正確な答え：{{簡潔な最終回答のみ}}

確信度：{{0% — 100%；根拠が弱い、曖昧、または欠落している場合は50%未満を使用してください。}}

C.3 LLMを審査員として

審査員用プロンプト

以下の「質問に対する回答」が、下記の正確かつ曖昧さのない「正解」に基づいて正しいかどうかを判定してください。

質問：[question]

回答：[response]

ご回答は、以下の形式および基準に従って行ってください：

Extracted_final_answer：回答から抽出された最終的な正確な答え。回答から抽出できる正確な最終的な答えがない場合は、抽出された答えを「None」としてください。

正解：[correct_answer]

理由：正解に基づいて、extracted_final_answerが正しいか間違っているかを説明してください。その際、正解とextracted_final_answerの間に意味のある相違があるかどうかのみ焦点を当ててください。問題の背景について言及したり、問題を解こうとしたり、正解とは異なる答えを主張したりせず、答えが一致しているかどうかのみに焦点を当ててください。

正答：extracted_final_answerが上記の「正解」と一致する場合、または数値問題において許容誤差の範囲内にある場合は「yes」と回答してください。それ以外の場合、すなわち不一致、曖昧さ、非同等性がある場合、または抽出された回答が正しくない場合は「no」と回答してください。

信頼度：レスポンスから抽出された0%～100%の信頼度スコア。信頼度スコアが利用できない場合は100と入力してください。

D ケーススタディ

このセクションでは、DCI-Agent-Lite および DCI-Agent-CC が、いかにしてより洗練され、効率的かつ堅牢な深層調査を行うかを示すケーススタディを紹介します。

D.1 事例 1：実証例

この事例では、知識集約型のQAタスクにおいて、当システムの基本的なエージェント型推論パラダイムを実証します。本モデルは、Natural Questionsベンチマークから単純な事実に関するクエリを受け取り、それを検索可能な用語に分解し、初期のアプローチでスケーラビリティの限界に直面した際には、検索戦略を反復的に洗練させます。検索エージェントとは対照的に、当エージェントはGrepやBashを用いてクローズドコーパスを直接操作し、構造化された文書コレクションに対して正確な語彙マッチングを実現します。

Natural Questions

質問：ドン・キホーテの馬の名前は何か

回答：ロシナンテ

成功事例

ターン1:

推論内容: ウィキコーパスからドン・キホーテの馬に関する情報を検索します。

ツール: Grep

ツール呼び出し:

```
{
  "pattern": "Rocinante",
  "path": "wiki_corpus/wiki_dump.jsonl",
  "output_mode": "content", "head_limit": 10
}
```

結果:

ドキュメント 135082: ロシナンテ (『ドン・キホーテ』に登場する馬) がポニーたちと交尾しようとする……

ドキュメント 135112: ロシナンテは小説に登場するドン・キホーテの馬である……

ターン2:

推論内容: 検索により直接的な証拠が見つかりました。文書ID 135082には「ロシナンテ (ドン・キホーテの馬)」と明示的に記載されており、文書135112がこれを裏付けています。より広い文脈を検索して確認してみましょう。

ツール: Grep

ツール呼び出し:

```
{
  "pattern": "Don Quixote.*horse",
  "path": "wiki_corpus/wiki_dump.jsonl",
  "output_mode": "content", "head_limit": 10
}
```

ターン3:

推論内容: ファイルが大きすぎて、grepでは効率的に検索できません。よりの絞ったBashのアプローチで、正確な確認情報を取得してみます。

ツール: Bash

ツールの呼び出し:

```
{
  "command": "grep -m 3 \"Rocinante\" wiki_corpus/wiki_dump.jsonl | head -c 1500", "timeout": 30000
}
```

結果:

```
{ "id": 339679, "contents": " ロシナンテに乗ったドン・キホーテは ..."}
{"id": 135082, "contents": " ロシナンテ（ドン・キホーテの馬）がポニーたちと交尾しようとし....."}
```

最終回答: 検索の結果、ウィキコーパス内で直接的な証拠が見つかりました。ドキュメントID 135082には、「ロシナンテ（ドン・キホーテの馬）がポニーたちと交尾しようとする」と明示的に記載されています。引用元: [wiki_corpus/wiki_dump.jsonl, id: 135082, qid: test_1135]。文書ID 339679 もさらに次のように裏付けている: 「ロシナンテに乗ったドン・キホーテ」 cite:[wiki_corpus/wiki_dump.jsonl, id: 339679, qid: test_1135]。すべての情報源において、その馬の名前は一貫して**ロシナンテ**と特定されている。

D.2 事例 2a: エージェント型検索における DCI-Agent-CC

この事例は、モデルがBrowseComp-Plus（深い調査と制約検証を必要とするエージェント型検索のベンチマーク）において、極めて難易度の高いマルチドキュメント推論問題にどのように取り組むかを示しています。クエリにはサッカーの試合に関する12の相互に関連した手がかりが含まれており、モデルは試合を特定し、コーパスの文書に対して各制約を検証し、対象エンティティを抽出する必要があります。完全なトレースは80ターンに及ぶますが、ここでは仮説の形成、制約の検証、および文書間推論という重要な局面に焦点を当てます。

BrowseComp-Plus

質問: 20世紀後半にサッカーの試合が行われた。この試合ではイエローカードが1枚提示され、両チームとも2回の選手交代を行った。試合は1対0で終了した。この試合は、50年以上前に建設されたスタジアムで、3万5千人未満の観客の前で行われた。3人の審判団はそれぞれ異なる国籍を持っていた。得点者は18歳でプロデビューし、そのデビューから試合が行われるまでの期間は10年未満だった。その後、インタビューで自身のゴールについて、パワーではなく「テクニック」で決めたと言った。また、次の試合でも得点を挙げた。敗れたチームのこの試合の先発メンバーには、得点者と同じ年に生まれた選手が2人おり、2人の生年月日は1ヶ月未満の差しかなかった。この2人のうち年上の選手は、同じ記事のインタビューで得点者のチームメイトからも言及されていたが、当時その選手が所属していたクラブの名前は何か？

答え: AJオセール

成功事例

第1ターン:

推論内容: この問題の手がかりを分析してみましょう: 1. 20世紀後半に行われたサッカーの試合 2. イエローカードが1枚 3. 両チームとも2人ずつ選手交代を行った 4. 最終スコア: 1-0
5. 観客数は35,000人未満 6. スタジアムは試合の50年以上前に建設された 7. 異なる国籍の審判員が3名 8. 得点者は18歳でプロデビューし、その時点から試合までの期間は10年未満 9. 得点者は（インタビューで）そのゴールがパワーではなく「テクニック」によるものだったと言った（インタビューで） 10. 得点者は次の試合でも得点を挙げた 11. 敗れたチームには、得点者と同じ年に生まれた選手が2人おり、2人の生年月日は1ヶ月未満の差しかなかった 12. この2人のうち年上の選手については、同じ記事のインタビューで得点者のチームメイトの1人が言及していた.....

ツール: ToolSearch

ツールの呼び出し:

```
{
  "query": "select:Grep,Bash"
}
```

ターン2:

推論内容: 手がかりから、これはワールドカップまたは欧州選手権の特定の試合に関するものかもしれない。ワールドカップのノックアウトステージに関する資料を確認し、絞り込みのヒントになるかどうか調べてみましょう。1970年から1993年までは、1チームあたり2回の選手交代が認められていましたが、1994年にルールが変更され、3回に増えました。現在、得点者の年齢とキャリアの経緯を確認しています。その選手は18歳でプロデビューし、この試合の10年未満前に得点を挙げています。

ツール: Bash

ツール呼び出し:

```
{
  "command": "ls browsecomp-plus-corpus/espn.co.uk/ | head -30", "description": "ESPN UKの記事を一覧表示",
}
```

結果:

```
England \_1 -0\ _Belgium \_ \_26 \_Jun \_ \_1990 \_ \_Final\ _Score . txt ペナルティのことは \_ 触れない
で \_。 \_1990年の \_ イングランド代表チームが \_ 振り返る \_
...
```

ターン3:

推論内容：espn.co.ukに「England_1-0_Belgium_26_Jun_1990_Final_Score.txt」というファイルがあります—1990年6月26日、イングランド 1-0 ベルギー。これはワールドカップの試合かもしれません！このファイルを確認してみましょう。また、「PK戦については触れないで：イングランドの1990年代表チームが、すべてを変えたワールドカップの試合を振り返る」という記述にも気づきました。両方のファイルを確認してみましょう。

ツール：Bash

ツール呼び出し：

```
{
  "command": "cat browsecomp-plus-corpus/espn.co.uk/England_1-0_Belgium_26_Jun_1990_Final_Score.txt",
  "description": "1990年のイングランド対ベルギー戦（1-0）の試合ファイルを読み込む",
}
```

結果：

最終スコアと結果 --- イングランド 1 - 0 ベルギー --- 1990年6月26日試合：1990年FIFAワールドカップ ベスト16
スタジアム：スタディオ・レナート・ダル・アラ（ポローニャ） 観客数：34,520人
得点者：デビッド・ブラット（119分） イエロー
カード：イングランド 1、ベルギー 0
イングランドの交代選手：2名、ベルギーの交代選手：2名 主審：ピーター・ミッケルセン（デンマーク）
副審：ピエールイジ・バイレット（イタリア）、ゾラン・ペトロヴィッチ（ユーゴスラビア）

第4ターン：

推理内容：興味深い！1990年6月26日のイングランド対ベルギー戦（1-0）は、デビッド・ブラットが120分にゴールを決めた試合だった！これがすべての手がかりと一致するかどうか確認してみよう：1. 20世紀後半のサッカーの試合—はい（1990年） 2. イエローカード1枚—はい 3. 両チームとも2回の選手交代—はい 4. 最終スコア：1-0—はい 5. 観客数35,000人未満—はい（34,520人）
6. 50年以上前に建設されたスタジアム—ポローニャのレナート・ダッラ・アラ・スタジアム—確認が必要 7. 異なる国籍の審判員3名—デンマーク、イタリア、ユーゴスラビア—はい 8～12. 得点者の詳細とベルギー代表選手について確認が必要。

ツール：Bash

ツール呼び出し：

```
{
  "command": "cat \"browsecomp-plus-corpus/theguardian.com/David_Platt_Italy_90_and_England_1_Belgium_in_the_players_own_words.txt\"",
  "description": "デイヴィッド・ブラットとイングランド対ベルギー戦に関するガーディアンの記事を読む",
}
```

結果：

デビッド・ブラット、イタリア90、そしてイングランド対ベルギー戦—選手たちの言葉から

デビッド・ブラット：「パワーはあまりなかった。すべてがテクニクだった。」 ポール・バーカー：「ベルギーは非常に経験豊富で、エンツォ・シフォという素晴らしい選手がいた。」

クリス・ワドル：「フランスでシフォと対戦したことがある……オセールで彼が何度もそのプレーをするのを見ていた。」

ターン5：

推論内容：デビッド・ブラットの「テクニク」という発言を裏付けるガーディアン紙の記事を入手した。また、ポール・バーカーがエンツォ・シフォに言及しており、クリス・ワドルも「オセールで彼がそれを何度もやっているのを見ていた」と述べている。これは答えがオセールであることを強く示唆している。しかし、確認のためにベルギー代表選手の生年月日を調べてみよう。

ツール：Bash

ツール呼び出し：


```
{
  "command": "cat \"browsecomp-plus-corpus/en.wikipedia.org/St\\_phane\\_Demol\\_\\_Wikipedia.txt\"",
  "description": "St\\_(e)phane Demolのウィキペディア記事を読む",
}
```

結果:

ステファン・デモル
 生年月日：1966年3月11日（年齢...） ポジション
 ：ディフェンダー

ターン6:

推論内容：ステファン・デモルは1966年3月11日生まれである。エンツォ・シフォは1966年2月19日生まれである。その差は20日——1ヶ月にも満たない！両者とも1966年生まれであり、デビッド・ブラット（1966年6月10日）と同じ年である。2人のうち、シフォの方が年上だ（2月対3月）。ポール・パーカーは『ガーディアン』紙のインタビューでシフォについて言及している。クリス・ワドルは、シフォが「オセールでそれを何度もやってのけるのを見た」と語った。したがって、所属クラブはAJオセールである。

ツール：Bash

ツール呼び出し：

```
{
  "command": "cat \"browsecomp-plus-corpus/en.wikipedia.org/Enzo\\_Scifo\\_\\_Wikipedia.txt\" | head -50",
  "description": "エンツォ・シフォのウィキペディア記事を読む",
}
```

結果:

エンツォ・シフォ
 生年月日：1966年2月19日 ポジション：
 MF
 所属クラブ：アンデルレヒト、インテル・ミラノ、ボルドー、オセール、トリノ、モナコ

正解：1990年FIFAワールドカップのベスト16で、イングランドがベルギーに1-0で勝利した試合です。得点者はデビッド・ブラット（1966年6月10日生まれ）です。1966年生まれで生年月日が1ヶ月未満しか離れていないベルギー代表の先発選手は、エンツォ・シフォ（1966年2月19日生まれ）とステファン・デモル（1966年3月11日生まれ）の2人で、その差はちょうど20日である。この2人のうち、シフォの方が年上である。『ガーディアン』紙のインタビューで、ポール・パーカーはシフォを「素晴らしい選手」と評し、クリス・ワドルは「オセールで彼がそのプレーを何度も見せてくれた」と付け加えている。したがって、当時シフォが所属していたクラブはAJオセールであった。

D.3 事例 2b：エージェント検索における DCI-Agent-Lite

このトレースは、BashとReadツールのみを備えた軽量版であるDCI-Agent-Liteが、多制約のBrowseComp-Plusクエリを正常に解決した様子を示している。エージェントは、出版日、プロットの詳細（戦車、スコアボード、瞳の色、ニックネーム）、著者の略歴といった手がかりから、ある本を特定しなければなりません。利用可能なツールセットは限られていますが、エージェントは的を絞った rg コマンドを用いて検索空間を段階的に絞り込み、候補となる文書を読み込んで答えを検証しています。

BrowseComp-Plus

問題：その本は2013年から2016年までの5月（両端を含む）に出版された。主人公は特定の種類の海の生き物で満たされた水槽を見つけ、ある少年と出会い、その少年の目の色に基づいてあだ名をつける。その本の校長はスコアボードに夢中になっている。著者は幼い頃から執筆や絵を描き始めていた。2023年12月以前、著者は余暇をビデオゲームに費やしていた。その本のタイトルは何ですか？

答え：『Made You Up』

成功事例

ターン1：

推論内容：（検索継続中...）

ツール：Bash

ツール呼び出し：

```
{  
  "command": "find bc_plus_docs -maxdepth 2 -type f | head"  
}
```

結果：

```
bc\_plus\_docs / seqlegal. com / 賞金付きコンテストと法律：迷宮を抜け出す方法 . txt  
bc\_plus\_docs / www. linzisfilmfestival. com /第8回 LINZ ISFF 8 2025年10月11  
  日. txt  
bc\_plus\_docs / www. frieze . com / ハリー・ニルソンの謎. txt bc\_plus\_docs / www .  
hampton . gov / フォート・モンロー . txt bc\_plus\_docs / www . beltandroadforum . org / 共有の  
  未来 中国の提案 と 行動 . txt bc\_plus\_docs / www . beltandroadforum  
  . org / 一帯...
```

ターン2：

推論内容：**ファイルの検索**

よし、各ディレクトリ内のファイルが.txt形式で整理されている点を考慮している。ファイル数が多くても処理できそうだ。検索を絞り込むのに役立つほど一意性が高いと思われる「scoreboard」というフレーズを探すために、コマンドラインツールの「rg」を使うことにしよう。これは良いアプローチだ。うまくいけば、結果を効果的に可視化できるはずだ！ どうなるか見てみよう！

ツール：Bash

ツールの呼び出し：

```
{  
  "command": "rg -n \"scoreboard\" bc_plus_docs --type-add 'txt:*.txt' --glob='*.txt' | head -n 50"  
}
```

結果：

```
bc\ _plus \ _docs / keepthescore . com / 野球のスコアリングの仕組み . txt :163: Keepthescore . com は、
オンラインスコアボードのトッププラットフォームであり、野球専用のスコアボードを提供
しています。
bc\ _plus \ _docs / keepthescore . com / 野球のスコアリングの仕組み . txt :165: このスコアボードは、携帯電話や
タブレット端末により、スコアキーパーはフィールド内を移動しながら、あるいはプレ
スボックスから作業を行いながらも、正確なスコアを記録することができます。
bc\ _plus \ _docs / keepthescore . com / 野球のスコアリングの仕組み . txt :193: これは...
```

結果:

[... 省略、31242文字が省略されました]

ターン3:

推論内容: (検索を継続中...)

ツール: Bash

ツール呼び出し:

```
{
  "command": "rg -n \"principal\" bc_plus_docs --glob='*.txt' --fixed-strings -S --no-mmap | head"
}
```

結果:

```
bc\ _plus \ _docs / arboretum . harvard . edu / Historical Biographies . txt :235: 1919年、ショーがハーバ
ード・カレッジの15周年記念同窓会誌に記した文章には、「私の主な活動は松の研究であり、その拠
点はアーノルド樹木園にある」とある。
bc\ _plus \ _docs / archive . bchananschools . com / Buchanan High School 1940 -1949. txt :31: 校長
bc\ _plus \ _docs / archive . bchananschools . com / ブキャナン高校 1940 -1949. txt :33:- ポール・ムーア氏
は1936年から1942年まで校長を務めた。
bc\ _plus \ _docs / archiv ...
```

ターン4:

推論内容: (検索を継続中...)

ツール: Bash

ツール呼び出し:

```
{
  "command": "rg -n \"tank\" bc_plus_docs --glob='*.txt' | head"
}
```

結果:

(出力なし)

[2行中2行を表示 (上限50.0 KB) 。 完全な出力 : pi - bash -77 d 19 cc 22550 d 7 c 2 . log
]

ターン5:

推論内容: **本に関する手がかりの検証**

「『Made You Up』の著者、フランチェスカ・ザッピアへのインタビュー」というタイトルの別のファイルに、2023年12月以前と思われる、彼女が執筆、絵を描くこと、ビデオゲームをすることに早くから興味を持っていたことが記されている可能性があることに気づきました。また、「The Lobster Tank」という言及もあり、これは物語に登場するロブスターで満たされた水槽に関連しているようです。出版日は2015年5月19日であることを確認する必要があります。主人公である青い目の少年や、校長がスコアボードに執着している点など、手がかりはよく一致しているようです。

****著者の経歴の確認****

2023年12月以前、著者が自由時間をビデオゲームに費やしていたと述べている点に注目しています。これは、執筆をしていないときはゲームをしていると彼女が語った2015年のインタビューと関連しているようです。しかし、正確性を確保するために、この情報をさらに確認する必要があります。

「thesweetsixteens」や「thesoundofyabooks」のファイルを確認すると参考になるかもしれません。また、著者が幼い頃から執筆や絵を描き始めていたかどうかについても確認したいです。例えば、「子供の頃から執筆や絵を描いてきました」といった記述がないか探してみてください。

ツール：Read

ツール呼び出し：

```
{
  "path": "thesoundofyabooks.wordpress.com/Interview Francesca Zappia, author of Made You Up.txt",
  "offset": 1,
  "limit": 250
}
```

結果：

タイトル：インタビュー：フランチェスカ・ザッピア（『Made You Up』著者） 著者：Smallstupiddeer

日付：2015年1月9日

公開日時：2015年1月9日 16:00:00 +00:00

インタビュー：フランチェスカ・ザッピア（『Made You Up』著者） | The Sound of YA Books
=====

『The Sound of YA Books』

お茶を片手に、素敵な本をお楽しみください メニュー

コンテンツへスキップ

ターン6：

推論 コンテンツ：（検索中...）

ツール：Read

ツール呼び出し：

```
{
  "path": "www.amazon.com/Made You Up Hardcover May 19, 2015.txt", "offset": 100,
  "limit": 120
}
```

結果:

彼は口元をほころばせて笑い、こう言った。「侮辱するなよ。」

「生きてるのか？」 「

ああ。」

「ここに住んでいるの？」

「ええ。」

「君、どこかで会ったことある？」

最終回答：この本はフランチェスカ・ザッピア著『Made You Up』です。

D.4 事例 3a：知識集約型QAにおけるDCI-Agent-CC

この事例は、標準的な知識集約型QAデータセットである「Natural Questions」ベンチマークにおいて、モデルがシングルホップの事実検索を実行できる能力を示しています。クエリは特定の映画での役柄について尋ねており、モデルは関連するウィキペディアの記事を迅速に特定し、その俳優の伝記と照合することで、出典を明記した確信度の高い回答を生成しています。

Natural Questions

質問：『コナン・ザ・デストロイヤー』で処女役を演じたのは誰ですか

回答：オリビア・ダボ

成功例

ターン1:

推論内容：「コナン・ザ・デストロイヤー」とその映画に登場する処女のキャラクターに関する情報を検索します。

ツール：Grep

ツール呼び出し：

```
{
  "pattern": "Conan the Destroyer", "path":
  "wiki_corpus/wiki_dump.jsonl", "output_mode":
  "content", "head_limit": 50
}
```

結果:

ドキュメント 1460759: 『コナン・ザ・デストロイヤー』

キャスト: アーノルド・シュワルツェネッガー、グレース・ジョーンズ、ウィルト・チェンバレン、トレイシー・オルター、オリビア・ダボ

ターン2:

推論の内容：「コナン・ザ・デストロイヤー」の記事（ID: 1460759）を見つけたのですが、内容が途切れていました。特に処女のキャラクターに関する部分など、さらに詳しい内容を確認する必要があります。「コナン・ザ・デストロイヤー」に関連して、処女のキャラクター／ジェナというキャラクターとオリビア・ダボについて具体的に検索してみます。

ツール：Bash

ツール呼び出し：

```
{
  "command": "grep -m 3 \"Jehnnal|Olivia d'Abo|Princess.*Conan\" wiki_corpus/wiki_
_dump.jsonl 2>&- | head -c 3000\"
}
```

結果:

ドキュメント 2205279: 彼は女王の姪であるジェナ（オリビア・ダボ）

、処女である.....を護衛することになっている.....

文書 4851059: ダ・アボの映画デビュー作は、『コナン・ザ・デストロイヤー』でのジェナ王女の助演役だった。

最終回答：証拠は明確である。コーパス内の文書ID 2205279にある『コナン・ザ・デストロイヤー』に関する記事には、次のように明記されている。「彼は、女王の姪であるジェナ（オリビア・ダボ）——処女——を護衛することになっている.....」また、文書ID 4851059にあるオリビア・ダボに関する記事では、「ダボの映画デビュー作は、『コナン・ザ・デストロイヤー』でのジェナ王女の助演役だった」と確認されている。これにより、**処女のキャラクターがオリビア・ダボが演じたジェナであることが直接的に特定される。**

D.5 事例 3b：知識集約型QAにおけるDCI-Agent-Lite

この事例は、大規模なローカル版ウィキペディアコーパスから事実に関する質問に答えるライトモデルの能力を示している。クエリは固有名詞ではなく数を尋ねているため、モデルはまず関連する都市とスポーツの文脈を検索し、その後、セントルイスに関連するNFLチームを列挙している正確な文を抽出する。

自然な質問

質問：セントルイスにはこれまでにいくつのNFLチームがあったか

回答：4つ

成功事例

ターン1:

推論内容: ローカルなウィキペディアのコーパスから答えを見つける必要があります。まずコーパスの構成を確認し、その後、セントルイスのNFLチームに関する記述を検索します。

ツール: Bash

ツール呼び出し:

```
{
  "command": "ls -la wiki\_corpus | head"
}
```

結果:

```
wiki\_dump . jsonl
```

ターン2:

推論内容: コーパスは単一の巨大なダンプデータです。同名の野球チームも存在するため、フットボールの文脈で「St. Louis Cardinals」を検索します。

ツール: Bash

ツール呼び出し:

```
{
  "command": "rg -n \"St\\. Louis Cardinals\\.\" wiki\_corpus/wiki\_dump.jsonl | head"
}
```

結果:

```
ドキュメント 200568: 1960年から1987年までのセントルイス・カーディナルス、および1995年から2015年ま
でのセントルイス・ラムズ...
```

ターン3:

推論内容: これはセントルイス市の記事のようで、完全なリストが含まれている可能性があります。完全な文を把握するために、そのドキュメント周辺の行を出力します。

ツール: Bash

ツールの呼び出し:

```
{
  "command": "python - <<PY\"nimport json\npath='wiki\_corpus/wiki\_dump.jsonl'\nlines\n=[200568,200569]\nfor nr in lines:\n    with open(path, 'r', encoding='utf-8') as f\n    :n        for i, line in enumerate(f, start=1):\n            if i == nr:\n                nobj = json.loads(line)\n                c = obj['contents']\n                start = c.find('St. Louis has been home') if 'National Football League' in c else c.find('St. Louis Cardinals')\n                print(c[start:start+500])\n                break\nPY\""
}
```

結果:

セントルイスは、これまでに4つの異なるナショナル・フットボール・リーグ（NFL）チームの本拠地となってきました。

1923年にはセントルイス・オールスターズが、1934年にはセントルイス・ガナーズが同市でプレーした
.....

1960年から1987年まではセントルイス・カージナルス、1995年から2015年まではセントルイス・ラムズが活動しました。

正解：セントルイスには、**セントルイス・オールスターズ、セントルイス・ガナーズ、セントルイス・カージナルス、セントルイス・ラムズの4つのNFLチーム**が存在しました。

D.6 事例4a：情報検索におけるDCI-Agent-CC

このケースは、BRIGHT-Biologyベンチマークにおける推論を多用する検索を提示する。これは、ドメイン固有の推論を必要とする情報検索タスクである。クエリは、昆虫の光走性に関する複雑な科学的質問であり、近因と究極の原因の区別を理解するとともに、競合する仮説（熱求向性対光駆動型方向性）を評価する必要がある。ゴールドエビデンスは、近因・遠因に関する記事と光走性に関する記事という2つの出典記事に分割されている。

BRIGHT-Biology

質問：昆虫が光に惹きつけられる理由に関する記事の主張について。この記事では、次のように述べることで、昆虫が光に惹きつけられる理由を論じています。「熱放射が誘引要因であるという説は、LED照明の効果によって反証されている。LED照明は無視できるほどの赤外線しか放射しないにもかかわらず、膨大な数の昆虫を捕らえているからだ。」しかし、LEDに惹きつけられることが、昆虫が熱を求めていることを示す理由が私には分かりません。例えば、昆虫は進化の過程で、光を熱と関連付けるようにプログラムされている可能性はないでしょうか？

Gold Documents：

- insects_attracted_to_light/Proximate_and_ultimate_causation_0.txt
- insects_attracted_to_light/Proximate_and_ultimate_causation_1.txt
- insects_attracted_to_light/Phototaxis_0.txt
- insects_attracted_to_light/Phototaxis_3.txt
- 光に誘引される昆虫/光走性_4.txt

回答：彼らは*近因的*な関係を探求し、説明しています。もし光が暖かくないにもかかわらず昆虫が光に向かって移動するのであれば、それは彼らが移動先を決定する際に*熱を利用していない*ことを意味します。彼らは究極的な根本的な動機については何も述べておらず、あくまで直接的な近因的なメカニズムについて論じているのです。彼らの代替モデルは、光駆動型の方位決定／光走性です。たとえ進化論的な説明が別のものであったとしても、昆虫は直接的な手がかりとして光に反応するのです。

成功事例

ターン1：

推論内容：生物学コーパスから、光に誘引される昆虫に関する文献を検索しよう。光走性に関する証拠と、近因と究極の原因の区別を説明している論文の両方を見つける必要がある。

ツール：Bash

ツール呼び出し：

```
{
  "command": "ls bright\corpus/biology/insects_attracted_to_light/", "description":
  "insects_attracted_to_light ディレクトリ内のファイルを一覧表示する",
}
```

結果：

```
Phototaxis \_0_.txt, Phototaxis \_1\_.txt, Phototaxis \_2\_.txt, Phototaxis \
\_3_.txt, Phototaxis\_4_.txt, Phototaxis\_5\_0_.txt
Light\_0\_.txt, Light\_1\_.txt, Light\_4\_.txt, Light\_5\_.txt, Light\
\_7\_.txt, Light\_9\_0_.txt
Insect\_*\_.txt、 Entomology \_.txt、 Proximate \_and \_ultimate \_causation \
*.txt
```

ターン2：

推論内容：質問に関連する特定のキーワード、「光走性」、「光刺激」、「正の光走性」、「近因」、「究極の原因」を検索してみましょう。

ツール：Grep

ツール呼び出し：


```
{
  "pattern": "phototaxis|light stimulus|positive phototaxis|proximate|ultimate causation",
  "path": "bright\\_corpus/biology/insects\\_attracted\\_to\\_light", "output\\_mode":
  "files\\_with\\_matches"
}
```

結果:

一致したファイル: Phototaxis _0 . txt , Phototaxis _3 . txt , Phototaxis _4 . txt , Proximate _and _ultimate _causation _0 . txt , Proximate _and _ultimate _causation _1 . txt

ターン3:

推論内容: 光走性に関する主要なゴールド文書は、Phototaxis_0.txt、Phototaxis_3.txt、およびPhototaxis_4.txtである。中核となる定義と、昆虫に特化したセクションを読み込む。

ツール: Bash

ツールの呼び出し:

```
{
  "command": "cat bright\\_corpus/biology/insects\\_attracted\\_to\\_light/Phototaxis\\_0.txt
  bright\\_corpus/biology/insects\\_attracted\\_to\\_light/Phototaxis\\_3.txt", "description": "Phototaxis_0.txt および
  Phototaxis_3.txt を読み込む",
}
```

結果:

光走性（Phototaxis）とは、生物全体が光という刺激に向かって、あるいはそこから離れて移動する際に生じる、一種の走性（taxis）または運動の一種である……

真の光走性……は、光の量が増加する方向へと、光の濃度勾配に沿って向かう指向性のある運動である……誘引物質は化学物質ではなく光である。

正の光走性（ポジティブ・フォトタキシス）は、蛾、バッタ、ハエなど、多くの飛翔昆虫に見られます。ショウジョウバエ（*Drosophila melanogaster*）は、光源に対する生来の正の光走性反応について、広く研究されてきました

…

都市や人口密集地域の人工照明は、より顕著な正の反応を引き起こし……その結果、生物はこの新たな超常刺激に対して繰り返し反応し、生来の習性に従ってそれに向かって飛んでいく。

ターン4:

推論の内容: これで光走性の証拠は揃った。さらに、「近因」と「究極原因」に関する重要な文献も読んでおこう。この質問は、昆虫が光を熱と関連付けるように「進化的にプログラムされている」可能性があるかどうかを具体的に尋ねているからだ。これこそが、近因（直接的なメカニズム）と究極原因（進化的な説明）の区別そのものである。

ツール: Bash

ツールの呼び出し:

```
{
  "command": "cat bright\\_corpus/biology/insects\\_attracted\\_to\\_light/Proximate\\_and\\_ultimate\\_causation\\_0.txt bright\\_corpus/biology/insects\\_attracted\\_to\\_light/Proximate\\_and\\_ultimate\\_causation\\_1.txt",
  "description": "Proximate\\_and\\_ultimate\\_causation\\_0.txt および Proximate\\_and\\_ultimate\\_causation\\_1.txt を読んでください",
}
```

結果:

近因とは、観察された結果に最も近い、あるいはその結果を引き起こす直接的な原因となる事象のことである。これは、より高次の最終原因とは対照的な概念である……

究極的な因果関係は、形質に作用する進化的力によってその形質を説明します。近因的な因果関係は、直接的な生理的または環境的要因によって生物学的機能を説明します。

最終回答： 関連資料（ゴールド証拠）：insects_attracted_to_light/Proximate_and_ultimate_causation_0.txt、insects_attracted_to_light/Proximate_and_ultimate_causation_1.txt、insects_attracted_to_light/Phototaxis_0.txt、insects_attracted_to_light/Phototaxis_3.txt、 および insects_attracted_to_light/Phototaxis_4.txt。熱／LEDに関する議論は近因に**関**するものである。すなわち、昆虫が低熱の光源に向かって移動するのであれば、熱は彼らが利用している直接的な手がかりではないということになる。光走性に関する資料は、光が近因としての誘引因子であることを裏付けており、飛翔昆虫における生得的な正の光走性について記述している。進化プログラミング仮説は**究極的な**説明であり、それ自体によって排除されるわけではない。単に、直接的なメカニズムとは別物であるに過ぎない。

D.7 事例 4b：情報検索における DCI-Agent-Lite

この事例では、DCI-Agent-LiteがBEIR-SciFact上で証拠に焦点を当てた検索を実行する様子を示している。クエリは生物医学的な主張であり、モデルは、非毒性の多結節性甲状腺腫における放射性ヨウ素治療を直接検証している正確な論文を特定すると同時に、関連はあるが関連性の低い甲状腺や線量測定に関する論文をフィルタリングして除外しなければならない。

BEIR-SciFact

質問：非毒性多結節性甲状腺腫に対する放射性ヨウ素治療は、甲状腺の体積を減少させる。

回答：はい。非毒性多結節性甲状腺腫において、放射性ヨウ素治療により甲状腺容積が減少しました。直接関連する文書は 9745001.txt です。

成功事例

ターン1:

推論内容：ローカルのSciFactコーパスのみを検索し、ランク付けの前にリコール率を最大化する必要がある。放射性ヨウ素、多結節性甲状腺腫、および甲状腺容積の減少について、いくつかのターゲットを絞った検索を実行する。

ツール：Bash

ツールの呼び出し：

```
{  
  "command": "rg -n \"radioiodine|radio-iodine|I-131|iodine-131\" . | head -n 50"  
}
```

結果:

```
./9745001.txt: 多結節性非毒性甲状腺腫に対する放射性ヨウ素治療 .  
./9745001.txt: 目的：放射性ヨウ素が甲状腺機能および甲状腺の大きさに及ぼす長期的な影響を調査すること.....  
./6751418.txt: 大型多結節性甲状腺腫に対する放射性ヨウ素療法の線量測定およびリスク推定 .  
./43122426.txt: 甲状腺機能亢進症に対する131-I放射性ヨウ素療法...
```

ターン2:

推論内容：最初の検索では甲状腺関連の論文がいくつか見つかったが、非毒性多結節性甲状腺腫と甲状腺の大きさを組み合わせて検討しているのは1件のみである。正確な疾患名と体積に関する結果について検索を行う。

ツール：Bash

ツール呼び出し:

```
{  
  "command": "rg -n \"non[-]toxic multinodular goitre|thyroid volume was reduced|60% reduction\" . | head -n 50"  
}
```

結果:

```
./9745001.txt: 目的：非毒性多結節性甲状腺腫患者における放射性ヨウ素の甲状腺機能および甲状腺サイズへの長期的な影響を調査すること.....  
./9745001.txt: ... 甲状腺容積の中央値は、  
24ヶ月時点で...  
./9745001.txt: ...60%の減少、p < 0.0001 ...
```

ターン3:

推論内容：他の多結節性甲状腺腫に関する文書が直接関連しているのか、それとも間接的な関連しかないのかを確認すべきである。多結節性甲状腺腫という表現を含むすべての文書をリストアップし、最も有力な候補を読み込む。

ツール：Bash

ツール呼び出し：


```
{  
  "command": "rg -l \\\"multinodular goitre|multinodular goiter\\\" . | head -n 50"  
}
```

結果:

```
./9745001.txt  
./6751418.txt  
./43122426.txt  
./26026009.txt
```

第4ターン:

理由の詳細: 候補ファイル「9745001.txt」は主張と直接一致しています。最終順位に含める前に、治療法、対象集団、および測定された転帰を確認するため、このファイルを読み込みます。

ツール: Read

ツール呼び出し:

```
{  
  "path": "9745001.txt"  
}
```

結果:

多結節性非毒性甲状腺腫に対する放射性ヨウ素治療。

目的: 非毒性多結節性甲状腺腫患者における、放射性ヨウ素が甲状腺機能および甲状腺の大きさに及ぼす長期的な影響を調査すること……

主要評価項目……治療前の超音波検査による甲状腺容積……

結果……24ヶ月時点で、甲状腺容積の中央値は73 mlから29 mlに減少した……60%の減少、 $p < 0.0001$ 。

結論: 甲状腺容積の著しい減少は……放射性ヨウ素の使用を、手術に代わる魅力的な選択肢としている……

最終回答: 関連文献（関連性の高い順、最も関連性の高いものから）: 9745001.txt。本論文は、非毒性多結節性甲状腺腫患者における放射性ヨウ素療法を直接的に研究しており、24ヶ月時点で甲状腺容積の中央値が73 mlから29 mlへと減少（60%の減少）したことを報告している。したがって、この主張は支持される。

D.8 事例 5a：エージェント検索における DCI-Agent-CC の失敗事例

この事例は、サッカーの試合での出来事や選手のレンタル移籍履歴についてマルチホップ推論を必要とする BrowseComp-Plus クエリにおいて、DCI-Agent-CC の失敗モードを示している。 エージェントは、2019年にイングランドのサッカー試合で発生したウォーターボトルをめぐる乱闘に関与した選手を特定し、その選手が欧州のクラブからレンタル移籍した経緯を追跡し、欧州大会において所属クラブのベンチ入りしていた際にどのチームと対戦したかを特定しなければならない。 エージェントはコーパス文書を通じてデニス・スアレスとFCバルセロナを正しく特定したものの、UEFAチャンピオンズリーグでのベンチ入りの対戦相手を誤って特定してしまった。

BrowseComp-Plus

質問：ある選手が2019年にイングランドで行われたサッカーの試合に関与した。彼は、ホームチームの選手が彼に水ボトルを噴射し、乱闘を引き起こした注目すべき出来事に関与した。この試合は、アウェイチームがシュート6本、イエローカード4枚、コーナーキック4本という結果で終了した。彼は、レンタル移籍先のクラブの欧州大会の試合でベンチ入りしていた。このベンチ入りした試合の対戦相手チームの名前は何か？

答え：FCクラスノダール

失敗例

ターン1:

推論内容：2019年にイングランドで発生した、選手が水ボトルで水をかけられ、乱闘が起きたというサッカーの事件について検索してみましょう。

ツール：ToolSearch

ツール呼び出し：

```
{
  "query": "select:Grep,Bash"
}
```

結果:

```
[{" type ": " tool\ _reference ", " tool\ _name ": " Grep "\}, {" type ": " tool\ _reference ", " tool\ _name ": " Bash "\}]
```

ターン2:

推論内容：2019年にイギリスで起きた水筒を噴射させた事件について検索してみましょう。

ツール: Grep

ツールの呼び出し:

```
{
  "pattern": "water bottle squirt", "path":
    "browsecomp-plus-corpus", "output_mode":
    "content",
  "-i": true,
  "-C": 5
}
```

ツール: Grep

ツール呼び出し:

```
{
  "pattern": "water bottle scuffle 2019", "path":
    "browsecomp-plus-corpus", "output_mode": "content",
  "-i": true,
  "-C": 5
}
```

結果:

一致する結果はありません

ターン 3 - 12:

推論内容：... エージェントは、複数のファイルやパターンを対象に広範な検索を継続し、サッカーの試合レポート、選手プロフィール、クラブのシーズンアーカイブなどを精査している...

...

12ターン目:

推論内容：arseblog.newsにアーセナルのレンタル移籍に関するファイルがあることに気づいた。それを見てみよう。また、問題文には、2019年にイングランドでウォーターボトル事件に関与した、欧州のクラブからレンタル移籍してきた選手について言及されている。

2019年の注目すべき事件を思い出してみよう：- 2019-20シーズンのチャンピオンシップ、ブレントフォード対ストーク戦.....違う。- もしかすると、QPRの選手が関わった事件だったかもしれない..... - 2019年10月、リーズ対カーディフが何かで事件があったような.....- いや、実はこれは2019年のミルウォールでの事件だったと思う。ある選手が誰かに水をかけたりしたあの件.....

- ベン・マーシャルやマーカス・タヴェルニエが関わった事件だったかもしれないし、あるいはバーミンガム・シティでの乱闘や、他のチャンピオンシップの試合で起きたことだったかもしれない。

2019年のチャンピオンシップの試合で、水ボトルを使ったトラブルがあった具体的な試合をコーパスで検索してみるか、あるいはその時期に欧州のクラブからレンタル移籍していた選手の名前を調べてみよう。

実は、アウェイチームがシュート6本、イエローカード4枚、コーナーキック4本という、まさにその統計条件に合致する試合を検索して絞り込むべきですね。

ツール：Bash

ツール呼び出し：

```
{
  "command": "find browsecomp-plus-corpus -name \"*.txt\" | xargs grep -l \"shots on target\\|shots on goal\" 2>&- | head -30",
  "description": "枠内シュート／ゴールへのシュートの統計データを含むファイルを検索する"
}
```

ツール：Bash

ツール呼び出し：

```
{
  "command": "cat browsecomp-plus-corpus/arseblog.news/Only_the_loany_Arsenal_s_loan_signings_listed_and_rated.txt | head -100", "description": "アーセナルのローン移籍に関する記事を読む"
}
```

結果:

タイトル : Only the loany -- アーセナルのローン移籍選手一覧と評価 著者: Arseblog

date : 2025年6月9日

アーセナルは多くの選手をレンタル移籍で送り出していますが、短期契約で加入してくる選手はごくわずかです。そこで、私たちは知恵を絞って、これまでレンタル移籍で加入した選手全員をリストアップし、北ロンドンでの短い在籍期間について評価してみました。

おそらく全員網羅できていると思いますが、その数は意外にも少ないです。もし見落としがあれば、コメント欄で教えてください。

まずは：

デニス・スアレス（バルセロナ） -- 2018/19

ターン13～55：

推論内容：... エージェントは、複数のファイルやパターンを幅広く検索し続け、サッカーの試合レポート、選手プロフィール、クラブのシーズンアーカイブなどを精査している...

...

55ターン目：

推論内容：非常に興味深い詳細を発見した！バルセロナは2018-19シーズン、アンドレ・ゴメスをエヴァートンに貸

し出していた！アンドレ・ゴメスは2018-19シーズン、バルセロナからエヴァートンへレンタル移籍していた。バルセロナは2018-19シーズン、チャンピオンズリーグに出場していた。

これはデニス・スアレスよりもはるかに符合する！アンドレ・ゴメスは2018-19シーズン、バルセロナからエバートンへレンタル移籍していた。2018-19シーズンのエバートンのアウェイ戦で、ゴメスに関わるウォーターボトル事件はあっただろうか？

問題文には「彼は、レンタル移籍先のクラブの欧州大会の試合でベンチ入りした」とあります。もしアンドレ・ゴメスが2018-19シーズンにバルセロナからエヴァートンへレンタル移籍していたとしたら、彼はバルセロナのチャンピオンズリーグの試合でベンチ入りしたことはありましたか？

しかし、ちょっと待ってください——もしゴメスが2019年5月までエバートンにシーズン通しのレンタル移籍していたとしたら、それを認める特別な条項がない限り、バルセロナのチャンピオンズリーグの試合に出場することはできなかったでしょう。また、この出来事が2019年に起きたという点も重要だ。これは、そのレンタル期間の終盤と重なる可能性がある。つまり、レンタルは2018-19シーズン限定だったということになり、その後ゴメスはバルセロナに戻ったか、エバートンと完全移籍したかのどちらかになる。もし2019-20シーズンにバルセロナに戻っていたなら、そのシーズンのチャンピオンズリーグの試合でベンチ入りすることは可能だったはずだ。しかし待ってください——彼は2019年11月、エバートン在籍中にあの深刻な足首の怪我を負っています。つまり、2019-20シーズンも、別のレンタル移籍か完全移籍のいずれかの形でエバートンに在籍していたはずです。それとも、完全移籍したのでしょうか？確認してみよう。実は、アンドレ・ゴメスが最初のレンタル期間終了後にエバートンと完全移籍で契約したと読んだ記憶がある。つまり、経緯は以下のようになる：- 2018-19シーズン：アンドレ・ゴメスがバルセロナからエバートンへレンタル移籍 - 2019年夏：エバートンがバルセロナからゴメスと完全移籍で契約 - 2019年11月：ゴメスがトッテナム戦で恐ろしい足首の怪我を負う

もしゴメスが2019年夏に完全移籍していたなら、2019年11月に足首の怪我を負った時点ですでにエバートンの完全所属選手だったことになります。したがって、「親クラブ（バルセロナ）の欧州大会でのベンチ入り」は、エバートンへの完全移籍以前にあったはずなのです。つまり、2018-19シーズンのレンタル期間中にバルセロナがチャンピオンズリーグの試合で彼をベンチ入りさせたか、あるいはエバートンへのレンタル移籍以前のシーズンでの欧州大会出場だったかのいずれかということになる。ゴメスがバルセロナで試合に出場したかどうかを確認するため、バルセロナの2018-19シーズンをさらに詳しく調べてみよう。また、レンタル契約において、彼がバルセロナとして欧州大会に出場することが認められていたのかも確認する。

ツール：Bash

ツール呼び出し：

```
{
  "command": "cat \"browsecomp-plus-corpus/en.wikipedia.org/2018_19_FC_Barcelona_season_-_Wikipedia.txt\" | grep -i \"Gomes\\|Andre\\|Everton\\| bench\\|Champions League\" -C 3 | head - 80",
  "description": "バルセロナの2018-19シーズンにおけるアンドレ・ゴメスの出場記録を検索する"
}
```

結果:

```
cup1 結果: 準優勝 cup2: スペイン・スーパーカップ cup2 結果: 優勝
cup3: UEFAチャンピオンズリーグ cup3 結果: 準決勝
リーグ得点王: リオネル・メッシ (36) シーズン得点王: リオネル・メッシ (51)
--
```

2018-19シーズンは、フットボール・クラブ・バルセロナにとって創設以来119シーズン目であり、スペインサッカーのトップリーグにおける88シーズン連続の参戦となった。バルセロナは、前シーズンにラ・リエガとコパ・デル・レイの2冠を達成した後、4つの大会に参戦した。

予想に反し、主にリオネル・メッシの圧倒的な活躍により、バルセロナは……の争いに加わっていた。

56～68ターン：

推論内容：...エージェントは、複数のファイルやパターンを横断して広範な検索を継続し、サッカーの試合レポート、選手プロフィール、クラブのシーズンアーカイブなどを精査している...

...

ターン68：

推論内容：2018-19シーズンのFCバルセロナに関する記事をさらに注意深く確認し、チャンピオンズリーグにおけるデニス・スアレスのベンチ入り出場を探してみます。

ツール：Bash

ツールの呼び出し:

```
{
  "command": "cat \"browsecorp-plus-corpus/en.wikipedia.org/2018
_19_FC_Barcelona_season_-_Wikipedia.txt\" | grep -i \"Suarez\\|Denis\\|bench\\| Champions
League.\" | grep \"Champions\\|UCL squad\\|PSV\\|Inter Milan\\| Tottenham\" -C 2 | head -80",
  "description": "バルセロナの2018-19シーズンにおけるデニス・スアレスとUCLのスタメン詳細を検索する"
}
```

結果:

9月15日、バルセロナはレアル・ソシエダを1-2で下した。前半終了時点でリードを許していたものの、スアレスとデンベレのゴールで流れを変え、リーガ・エスパニョーラで4戦全勝を達成した。

9月18日、バルセロナは今シーズンのチャンピオンズリーグ初戦でPSVアイントホーフェンを4-0で下した。記録を更新するチャンピオンズリーグ通算8度目のハットトリックを達成し、デンベレも独力で残りの1ゴールを決め、ブラウグラナのさらなる勝利を飾った。

9月23日、バルセロナはジローナと2-2で引き分けた。レンクレの退場がホームチームを苦しめ、メッシとピケは...

ターン69:

推論内容: 重要なデータを見つけました！2018-19シーズンのバルセロナに関する記事に、チャンピオンズリーグの登録メンバーを示す表があります。その記事によると、デニス・スアレスのアーセナルへの移籍は「2019年1月31日、シーズン終了まで、MF、6、デニス・スアレス、アーセナル、なし」と記載されています。これにより、レンタル移籍が2019年1月31日に開始されたことが確認できる。さて、バルセロナのUCLグループステージを見てみると、試合は2018年9月、10月、11月、12月に行われた。デニス・スアレスは当時まだアーセナルへレンタル移籍していなかった（彼は2019年1月に加入した）。したがって、彼はバルセロナのUCLグループステージの試合でベンチ入りしていた可能性がある：

現在、秋から冬にかけて行われた実際のグループステージの試合を精査し、各試合に出場した選手を確認するためにメンバー統計をチェックしています。出場記録を見ると、ラフィーニャのような選手は、途中出場が1回のみと、関与がごくわずかだったことがわかります。

レンタル移籍の情報によると、デニス・スアレスは2019年1月31日までバルセロナに在籍していたことが確認されており、アーセナルへの移籍前のチャンピオンズリーグ初期の試合において、彼がメンバーの一員であった可能性は十分にある。重要なのは、彼が実際にどの試合に出場したかを特定することです。つまり、デニス・スアレスは2018年後半のグループステージ期間中、バルセロナに在籍しており、2019年1月にアーセナルへ移籍したため、ノックアウトステージには出場資格がありませんでした。問題では、グループステージ期間中に彼がベンチ入りしていた対戦相手がどこだったかが問われており、候補としてはPSVアイントホーフェン、トッテナム・ホットスパー、あるいはインテル・ミラノが挙げられます。記事のUCL登録メンバーのセクションを確認し、特定の試合でベンチ入りしたとの記載があるかどうか調べる必要があります。

ツール: Bash

ツールの呼び出し:

```
{
  "command": "cat \"browsecorp-plus-corpus/en.wikipedia.org/2018
_19_FC_Barcelona_season_-_Wikipedia.txt\" | grep -A 200 \"Group stage\" | head
-120",
  "description": "バルセロナの2018-19シーズンUCLグループステージの詳細とメンバー情報を読み込む"
}
```

結果:

グループステージ ノック

アウトステージ ベスト16

準々決勝 準決勝 統計

ターン70:

推論内容:重要な発見! 得点者一覧には「デニス・スアレス | 0 | 0 | 2 | 0 | 2」と表示されている

これは、デニス・スアレスが2018-19シーズンのコパ・デル・レイでバルセロナに2ゴールを挙げたが、ラ・リーガでは0ゴール、チャンピオンズリーグでも0ゴールだったことを意味する。彼はコパ・デル・レイには出場したが、チャンピオンズリーグの試合には出場していない（少なくとも得点はしていない）。待てよ、しかし問題文には、彼がバルセロナの一員として「ベンチ入り」した「ヨーロッパの試合」（チャンピオンズリーグ）があったと書かれている。コパ・デル・レイは国内カップ戦です。「欧州の試合」とは、チャンピオンズリーグまたはヨーロッパリーグを指します。スアレスがコパ・デル・レイで得点（2ゴール）を挙げたのであれば、彼は間違いなくバルセロナの一員としてコパ・デル・レイの試合に出場していたことになります。

UCLでの得点数がゼロであるだけでは、彼がチャンピオンズリーグの試合でベンチ入りしていたかどうかは判断できません——登録はされていたものの、出場機会がなかった可能性もあります。2018年秋のグループステージ当時、彼はバルセロナに所属していたため、おそらくメンバーには入っていたでしょうが、実際にどのチームのベンチにいたのかを突き止める必要があります。

バルセロナの2018-19シーズンのグループステージの対戦相手——PSV、トッテナム、インテル——を確認し、デニス・スアレスが2019年1月下旬にアーセナルへレンタル移籍したことを考慮すると、時系列は合致する。つまり、彼はグループステージではバルセロナのベンチ入りし、その後アーセナルに移籍してシーズン後半に出場した可能性がある。もしウォーターボトル事件が2019年のイングランドでのアーセナルのアウェイ戦で起きたのであれば、それは彼のアーセナルへのレンタル移籍期間と完全に一致する。アーセナルへのレンタル移籍が始まる前の、バルセロナの欧州大会での試合だ。

したがって、タイムラインは次のようになる：バルセロナのUCL試合でベンチ入り → その後、2019年1月にアーセナルへレンタル移籍。これは、すでに他クラブへレンタル移籍中にもかかわらずバルセロナでプレーしていたという説よりも理にかなっている。

現在、バルセロナの2018-19シーズン・チャンピオンズリーグのグループステージの試合を調べて、デニス・スアレスがベンチ入りしていた試合を探している。

待てよ、ここには論理的な矛盾がある——もし彼がその期間中に他のクラブへレンタル移籍していたなら、バルセロナの登録メンバーには含まれていなかったはずだ。これが本当にデニス・スアレスなのか、それとも全く別の選手なのか、改めて検討してみよう。

実際、バルセロナの2018-19シーズンについて私が知っていることを振り返ると、パコ・アルカセルは2018年8月からボルシア・ドルトムントへレンタル移籍しており、その年ドルトムントはチャンピオンズリーグに出場していた。しかし、ドルトムントはドイツのクラブであってイングランドのクラブではないため、これも条件に合わない。アルカセルがドルトムント以前に他のクラブへレンタル移籍していたかどうかを検討する必要がある。

2018-19シーズン中に実際にイングランドのクラブへレンタル移籍したバルセロナの選手たちを改めて検討してみよう。確認したところ、アンドレ・ゴメスがエヴァートンへ、デニス・スアレスがアーセナルへ移籍しており、どちらもイングランドのクラブだ。特にアンドレ・ゴメスの場合、2018-19シーズンを通してエヴァートンにレンタル移籍していたため、バルセロナのチャンピオンズリーグの戦いに参加することはできなかったはずだ。

デニス・スアレスの方が有力な候補のように思える。彼はアーセナルへのレンタル移籍前に2019年1月までバルセロナに在籍していたため、2018年秋に行われたPSV、トッテナム、インテル・ミラノとのチャンピオンズリーグ・グループステージの試合で、ベンチ入りしていた可能性があるからだ。現在、2019年初頭にスアレスがアーセナルにレンタル移籍中だった際、アウェイ戦で何か事件があったかどうかを確認しているところだ。スアレスが負傷したのは、BATEボリソフ戦のどちらの試合だったのかを特定する必要がある——2月14日のベラルーシでの第1戦（アウェイ）か、2月21日のホームでの第2戦か。いずれにせよ、彼は途中出場してわずか12分後に鼠径部の負傷によりピッチを去った。

質問では2019年のイングランドでの出来事について具体的に尋ねられているため、ベラルーシでの欧州アウェイ戦は該当しません。したがって、その時期のアーセナルのプレミアリーグのアウェイ戦——2月2日のハダースフィールド戦や2月24日のサウサンプトン戦など——に注目すべきでしょう。これらの試合で、スアレスが途中出場し、ウォー

ターボトル事件を起こした可能性があるからです。そこで、アーセナルが6本のシュート、4枚のイエローカード、4本のコーナーキックを記録したアウェイ戦がどれか、試合統計を確認している。実際に確認できる事実に基づいて検討する必要があることに気づきました。デニス・スアレスは2018年秋、PSV、トッテナム、インテル・ミラノと対戦したチャンピオンズリーグのグループステージ期間中、バルセロナに所属しており、その後2019年1月31日からアーセナルへ期限付き移籍しました。ウォーターボトル事件は、そのシーズンのイングランド国内で行われたアーセナルのアウェイ戦で発生しましたが、具体的な試合記録にアクセスできないため、どの

試合だったかを特定することはできません。登録規則では相当な人数の登録が認められているため、2018-19シーズンのチャンピオンズリーグ・グループステージ期間中、スアレスが実際にバルセロナの登録メンバーとして登録され、出場可能だったかどうかを調べています。コバ・デル・レイでの出場記録からは、ある程度プレー機会を得ていたことがうかがえますが、入手可能な情報からは、それらの特定の試合で彼がUCLのベンチ入りしていたかどうかについて、具体的な証拠はありません。この出来事が、スアレスが出場していたアーセナル戦でのものだったかどうか、改めて検討しています。そうであれば、メディアで大きく取り上げられた出来事となるからです。水ボトルを噴射した場面はバーンリー戦やチェルシー戦だった可能性もありますが、確信はありません。どのチームだったかについて推測し続けるよりも、この特定の出来事についてコーパスをより直接的に検索すべきでしょう。

ツール: Bash

ツール呼び出し:

```
{
  "command": "find browsecomp-plus-corpus -name \"*.txt\" | xargs grep -i \"Denis Suarez\\|Suarez.*Arsenal\\|Arsenal.*Suarez\" 2>&- | head -10",
  "description": "デニス・スアレスのアーセナルに関する記事を探す"
}
```

ツール: Bash

ツール呼び出し:

```
{
  "command": "find browsecomp-plus-corpus -name \"*.txt\" -path \"*/swanseaacity.com/*\" | head -5; cat browsecomp-plus-corpus/swanseaacity.com/Players_of_the_past.txt 2>&- | grep -i \"loan\\|2019\\|European\\|water\\|bottle\" -C 2 | head -30", "description": "スウォンジー・シティの過去の記事から、ローン移籍中の選手を確認する"
}
```

結果:

browsecomp - plus - corpus / swanseaacity . com / Players \ _of\ _the \ _past. txt ピーター・アボット

ストライカーのピーター・アボットは、スウォンジー・シティでハリー・グレッグ監督率いるチームの一員だった。マンチェスター・ユナイテッドの元育成選手である彼は、1970年10月にプロデビューを果たしたが、トップチームでの定位置を確保できず、1974年2月に当初はレンタル移籍の形でヴェッチ・フィールドへ移籍した。同月、ホームで行われたストックポート戦（3-0で勝利）でリーグデビューを果たし、1976年5月にハートフォード・バイセンテニアルズへ移籍するまでに、スウォンジーで4部リーグの41試合に出場し、3得点を挙げた。1976年8月、クルー・アレクサンドラでハリー・グレッグと再会し、彼は

71〜78ページ:

推論内容: ...エージェントは、複数のファイルやパターンを横断して広範な調査を続け、サッカーの試合レポート、選手プロフィール、クラブのシーズンアーカイブなどを精査している...

...

78ターン:

推論内容: UCLのセクション周辺のバルセロナのシーズンページを読み、デニス・スアレスのベンチ入り出場記録を探します。

ツール: Read

ツール呼び出し:

```
{
  "file_path": "browsecomp-plus-corpus/en.wikipedia.org/2018_19_FC_Barcelona_season_-_Wikipedia.txt", "offset": 370,
  "limit": 120
}
```

結果:

370 -> 準々決勝
371 ->
372 -> 準決勝
373 ->
374 -> 決勝
375 ->
376 -> スペイン・スーパーカップ
377 ->
378 -> 2017-18シーズンのコパ・デル・レイおよび2017-18シーズンのラ・リーガで優勝したバルセロナは、シーズン開幕戦となるスーペルコパ・デ・エスパーニャで、コパ・デル・レイの準優勝チームであるセビージャと対戦した。この大会の歴史上初めて、中立の会場で行われる一発勝負の試合となり
モロッコのタンジェにあるスタッド・イブン・バトゥータで行われた。
379 ->
380 -> UEFAチャンピオンズリーグ
381 ->

ターン79～89：

推論内容：...エージェントは、複数のファイルやパターンを横断して広範な検索を続け、サッカーの試合レポート、選手プロフィール、クラブのシーズンアーカイブなどを精査している...

89ターン：

推論内容：そのBBCの記事は、2024年のUEFAカンファレンスリーグにおけるラーンに関するものであり、デニス・スアレスや2019年の事件に関するものではない。

予算が底をつきそうです。現時点で分かっていることを整理してみましょう：

1. デニス・スアレスは2019年1月31日にバルセロナからアーセナルへレンタル移籍した
2. バルセロナの2018-19シーズンUCLグループBの対戦相手：PSVアイントホーフェン、トッテナム・ホットスパー、インテル・ミラノ
3. デニス・スアレスは2018-19シーズンのバルセロナ在籍時にUCLで得点を記録していないが、ベンチ入りしていた可能性はある
4. デニス・スアレスがどのUCLの試合でベンチ入りしていたかを確認できる具体的な資料が見つからない
5. また、ウォーターボトル事件そのものに関する具体的な証拠も見つかりません

確認できた情報に基づくと、デニス・スアレスは2018年秋に行われたバルセロナのUCLグループステージの試合で、1月にアーセナルへレンタル移籍する前、ベンチ入りしていた可能性が高いですが、質問で言及されている特定の試合やウォーターボトル事件を裏付ける資料は手元にありません。

バルセロナの2018-19シーズン・グループBでは、PSVアイントホーフェン、トッテナム・ホットスパー、インテル・ミラノと対戦しました。質問には、アウェイチームによるシュート6本、イエローカード4枚、コーナーキック4本という非常に具体的な試合統計が含まれており、コーパス内でこれらが見つかりさえすれば、その試合を特定できるはずです。どの対戦相手だったかを推測するのではなく、これらの正確な数字を検索してみます。また、コーパスからはデニス・スアレスのベンチ入りに関する明確な情報が得られないため、これは全く別のレンタル選手に関する話ではないかと考えています。

マーティン・オデガードはどうでしょうか？彼は2018-19シーズンと2019-20シーズン、レアル・マドリードからレアル・ソシエダへレンタル移籍していました。レアル・ソシエダはスペインのクラブであり、イングランドのクラブではありません。したがって、これは当てはまりません。

ルーベン・ロフタス＝チークはどうでしょうか？彼はイングランド人選手で、欧州のクラブからのレンタル移籍ではありませんでした。シェルダン・シャキリはどうでしょうか？彼はストーク／リヴァプールに所属しており、欧州のクラブからのレンタル移籍ではありませんでした。

待てよ——香川真司はどうだろう？彼はボルシア・ドルトムント（欧州のクラブ）に所属しており、レンタル移籍先は.....2019年にイングランドのクラブにレンタル移籍していたかどうかは定かではない。

いや、改めて考えてみよう。質問には「2019年のイングランドでのサッカーの試合」とある。これはかなり具体的だ。そして「彼は、レンタル移籍元のクラブのヨーロッパの試合でベンチ入りした」とある。これは、そのヨーロッパの試合が、この話に関連する時期に開催されたことを示唆している。

今、アレクシス・サンチェスのことを考えています——彼は2019年8月にマンチェスター・ユナイテッドからインテル・ミラノへレンタル移籍していました。しかし、これは逆の方向です。彼はイングランドからヨーロッパへ移ったのです。この質問は、欧州のクラブからイングランドへレンタル移籍した選手が、その後、親クラブの欧州大会でベ

ンチ入りしたケースについて尋ねているようです。マンチェスター・ユナイテッドは、イングランド国外に本拠地を置くという意味での「欧州のクラブ」とは言えないため、これも完全に当てはまりません。

別の検索方法を試してみよう——2019年のサッカー試合における「ウォーターボトル」事件や特定の乱闘騒ぎを探せば、絞り込みに役立つかもしれない。

ツール：Bash

ツール呼び出し：


```
{
  "command": "find browsecomp-plus-corpus -name \"*.txt\" | xargs grep -li \"scuffle\\| altercation\" 2>&- | xargs
grep -li \"2019\\|football\\|Premier\\|Arsenal\\|loan\" 2>&- | head -10",
  "description": "サッカーの文脈で「scuffle」または「altercation」を含むファイルを検索する"
}

ツール: Bash
ツール実行:

{
  "command": "find browsecomp-plus-corpus -name \"*.txt\" | xargs grep -li \"shots on goal\\|shots on target\"
2>&- | xargs grep -li \"corner\\|yellow card\" 2>&- | head
-20",
  "description": "シュート数、コーナーキック数、イエローカードの統計データを含むファイルを検索する"
}

結果:

browsecomp - plus - corpus / afordawards . co. uk/A\\_to \\_Z\\_Glossary \\_of\\_Football\\
_and \\_Soccer\\_Terms . txt
browsecomp - plus - corpus / archive . nytimes . com / Soccer\\_Made \\_in \\_the \\_U.S.\\_\\
_Where \\_M.L.S.\\_Stands \\_\\_Soccermetrically \\_Speaking . txt
browsecomp - plus - corpus / arsenal.com / 記録を更新した\\_2024年の\\_背後にある\\_統計\\
_2024 . txt
browsecomp - plus - corpus / atlutd . com / アトランタ・ユナイテッド、CFモントリオールに敗れる\\
_al\\_に2-1で敗れる . txt
browsecomp - plus - corpus / atlutd . com / アトランタ・ユナイテッド、勇敢な奮闘も及ばず
\\_ベスト・オブ・3\\_プレーオフ\\_シリーズの\\_第1戦\\_で\\_インター\\_マイアミ\\_に\\_及ばず\\_敗れる\\_ . txt
browsecomp - plus - corpus / cbsspo ...
```

ターン 90 - 92:

推論内容: ... エージェントは、複数のファイルやパターンを横断して広範な検索を続け、サッカーの試合レポート、選手プロフィール、クラブのシーズンアーカイブなどを精査している ...

ターン 92:

推論内容: OK、コーパス内では、デニス・スアレスがどのUCLの試合でベンチ入りしていたかについての具体的な情報を見つけることができませんでした。

そこで、この質問がデニス・スアレスのバルセロナでの他の欧州大会での出場を指している可能性について検討してみよう。しかし、バルセロナがUCLに出場したのは2018-19シーズンだけだった（コパ・デル・レイにも出場したが、これは国内大会であり、欧州大会ではない）。

待てよ——実際、コパ・デル・レイは国内大会だが、スーペルコパ・デ・エスパーニャも国内大会だ。バルセロナの欧州大会はUCLのみだった。

さて、PSVアイントホフフェン、トッテナム・ホットスパー、インテル・ミラノという選択肢があり、デニス・スアレスがバルセロナの一戦においてベンチ入りしていた可能性が高いという事実を踏まえると、どの試合だったのかを特定する必要があります。

これら3つの対戦相手とのグループステージの対戦カードを確認しているが、それらの試合の具体的なメンバー表にアクセスできないため、彼がどの試合でベンチ入りしていたかを正確に特定することはできない。

11月6日のインテル・ミラノ戦について、資料に実際に何が書かれているか確認してみよう——そこには、1-1の引き分けでバルセロナのゴールを決めたのはマルコムであると記載されており、私が当初考えていたラフィーニャではない。したがって、詳細を確認するために得点者一覧表を確認する必要がある。ラフィーニャはUCLで得点を挙げており、マルコムもそのシーズンのUCLで得点を挙げていて——両者ともこの大会で1ゴールずつ記録している。具体的な試合詳細を確認すると、本文ではマルコムがインテル・ミラノ戦で得点を挙げたと記載されている一方で、得点者一覧にはラフィーニャのUCLでの得点が記載されているため、各選手がどの試合で得点を挙げたのかを特定する必要がある。バルセロナの2018-19シーズンのUCLの試合を遡って、各ゴールがどの試合で生まれたのかを確認してみよう。コーパスから得点者を確認しました。インテル戦のホームゲームではラフィーニャとジョルディ・アルバ、アウェイ戦ではマルコムが得点しています。デニス・スアレスはそのシーズンのUCLのどの試合でも得点していません。また、一般的な知識から、11月のサン・シーロでの試合ではベンチ入りしていた可能性が高いことは分かっていますが、この質問は、彼がベンチ入りしていた特定の注目すべき欧州の試合について尋ねているようであり、その試合を特定しようとしています。

ツール : Bash

ツール呼び出し：

```
{
  "command": "find browsecomp-plus-corpus -name \"*.txt\" | xargs grep -li \"Tottenham
  .Barcelona\\Barcelona.*Tottenham\\Champions League.*2018\\UCL.*2018\" 2>&- | grep -v
  \\2018_19_FC_Barcelona\\2018_19_Uefa_Champions\" | head -10", "description": "UCL 2018-19 トッテナム対バル
  セロナに関連するファイルを検索"
}
```

結果:

```
browsecomp - plus - corpus / aanda . org / Editors \_ofl _A\ _A. txt
browsecomp - plus - corpus / aanda . org / ケプラー観測対象の特性評価 \_ofl _Kepler\ _targets \
  _中解像度\_LAMOST\_スペクトル\_に基づく\_ケプラー観測対象の\_特性解析\_ (ROTFIT\
  .txt
browsecomp - plus - corpus / aaqr.org / 50 \_年にわたる\_友情\_についての\_考察 \
  _エアロゾル\_科学\_および\_技術\_における\_50\_年間の\_友情\_と\_協力\_についての\_考察 . txt
browsecomp - plus - corpus / aaregistry . org / 人物 \_ \_場所 \_ \_エピソード \
  _33331.txt
browsecomp - plus - corpus / about.underarmour.com / Our\_Company .txt browsecomp - plus - corpus /
  about.underarmour.com / ANNUAL \_REPORT .txt browsecomp - plus - corpus /...
```

最終回答：利用可能なコーパスの全証拠に基づき、ベンチに姿を見せたのは、2018-19 UEFAチャンピオンズリーグ・グループBの試合における**FCバルセロナ**でした。その試合の対戦相手は、**インテル・ミラノ（インテルナツィオナーレ）**でした。

D.9 事例 5b：エージェント型検索における DCI-Agent-Lite の失敗事例

このトレースは、BrowseComp-Plusの映画識別タスクにおけるDCI-Agent-Liteの失敗モードを示しています。エージェントには、互いに絡み合う複数の手がかり（2000年代公開、貧乏から大富豪へのストーリー、1960年代生まれの俳優、2023年11月の監督と俳優の兄弟間の争い）が与えられていますが、正確な検索クエリを構築するのに苦労しています。エージェントは、無関係な文書を返す過度に広範なrgパターンを繰り返し発行し、正しいコーパスファイルに収束できず、最終的には表面的なキーワードの一部と一致するだけの誤った回答（『ファミリー・マン』）を誤って生成してしまいます。

BrowseComp-Plus

質問：2000年代に公開された映画のタイトルを教えてください。この映画は、贅沢な環境に育った人物と貧しい環境に育った人物という、全く異なる背景を持つ2人の人物が主人公です。両方の俳優は1960年代生まれです。2023年11月時点で、この映画の監督は、ある俳優の兄弟とトラブルを抱えていました。

回答：『Dosti: Friends Forever』

失敗例

ターン1：

推論内容：（検索中...）

ツール：Bash

ツール呼び出し：

```
{
  "command": "rg -n -i \"nov(ember)?\\s*2023\" bc_plus_docs | head"
}
```

結果：

```
bc\ _plus \ _docs / cloudcovermusic . com / Music for Business \ _ _docid \ _69513 . txt
:135: Spotify Wrapped 2023: ファンにとって音楽ジャンルはもはや無関係 . (2023年11月). BBC .
bc\ _plus \ _docs / cri. org / Unholy Guacamole . txt :9: 2023年11月 bc\ _plus \ _docs / cri. org / Unholy
Guacamole . txt :1507: 10社のうち
```

私たちが連絡を取った企業の中で、回答を返してくれたのはドル、フレッシュ・デル・モンテ、ネイチャーズ・ブライドの3社のみであり、その回答も限定的で定型的な情報にとどまっていました。これらの企業からは、適切なデューデリジェンスを行っているという兆候は一切見られませんでした.....

ターン2：

推論内容：（検索を継続中.....）

ツール：Bash

ツール呼び出し：

```
{
  "command": "rg -n -i \"director\" bc_plus_docs | rg -n -i \"brother\" | head"
}
```

結果：

```
345: bc\ _plus \ _docs / galachoruses . org / History . txt :83:2010 - 2010年
```

マネージャーおよびディレクターのリトリートが1月8日から10日にかけてツーソンで開催され、48名の代表者が出席しました。キャスリーン・マクガイア博士と米国からの5名の歌手は、2010年4月2日から4日にかけてニュージーランドのオークランドで開催された「OUT and LOUD フェスティバル」に参加し、そこで他の20名の歌手と共に、フェスティバルの一環として演奏を行った米国合同合唱団に加わりました。

5月21日から24日にかけてウィニペグで開催された「カナディアン・ユニゾン・フェスティバル」の開会式では、米国の複数の合唱団からのビデオメッセージが上映されました

21日から24日にかけてウィニペグで開催された「カナダ・ユニゾン・フェスティバル」の開会式では、米国のいくつかの合唱団からのビデオメッセージが上映されました。GALAのいくつかの...

ターン3：

推論内容：**検索戦略の絞り込み**

「監督」や「兄弟」で検索すると無関係な結果が多数表示されるため、このアプローチは範囲が広すぎると気づきました。「dispute」や「actor」といった用語を含めるよう、検索を絞り込む必要があります。「director said」や「actor's brother」といった、より具体的なフレーズ検索がここで役立つでしょう。手がかりには、2023年11月頃に監督が俳優の兄弟とトラブルになったことが記載されており、これに関連するニュース記事が見つかる可能性があります。しかし、まずはその具体的なトラブルに焦点を当てる必要があります。

検索条件の絞り込み

1960年代生まれの俳優と、2023年11月に俳優の兄弟が関与した監督とのトラブルに焦点を当てる必要があります。これはハリウッドでもハリウッドでも構いません。「裕福なカップルと貧しいカップルの対比」を描いた映画を想定していますが、「Parineeta」は当てはまりません。「dispute」というキーワードに、「俳優の兄」や「～の兄」といった用語を組み合わせて検索する予定です。これらのフレーズに正規表現 (regex) を使用すれば、検索結果を絞り込み、必要な文脈を見つけやすくなるかもしれません。

ツール: Bash

ツール呼び出し:

```
{
  "command": "rg -n -i \"actor\"?s brother|actor brother|brother of the actor|actor's sibling\" bc_plus_docs | head"
}
```

結果:

```
bc\ _plus \ _docs / www . netflix . com / 「ゴール」の価値があるサッカー映画10選 . txt :31: アカデミー賞受賞の脚本家兼監督、パオロ・ソレンティーノが、自身の10代の青春時代を基にした、心に響くフィクション形式の自画像を描き出している。物語の舞台は、1980年代のナポリ。ナポリのサッカーの伝説的選手ディエゴ・マラドーナは、1986年のワールドカップで、技術的にはハンドとみなされるゴールを決め、イタリア代表を優勝に導いた。内向的な16歳のファビエット（フィリッポ・スコッティ）は、大喜びする。若いソレンティーノの分身であるファビエットは、熱狂的なサッカーファンであり、...で哲学を学びたいと願っている.....
```

ターン4:

推論内容: **検索コマンドの最適化**

フレーズを検索するためのコマンドラインの使い方を模索している。当初は正規表現 (regex) パターンを使用することを考えていたが、「rg」は行単位で処理され、複数行に対応していないため、期待通りに機能しない可能性があることに気づいた。その代わりに、「director」または「actor」のいずれかを含む行の中から、「dispute」という単語を探すことにします。検索結果をさらに絞り込むために、2段階のパイプラインアプローチを用いて、結果の中から「brother」をフィルタリングする予定です。さあ、やってみましょう！

ツール: Bash

ツール呼び出し:

```
{
  "command": "rg -n -i \"(dispute.*director|director.*dispute|dispute.*actor|actor.*dispute|disputed.*director|director.*disputed|disputed.*actor|actor.*disputed)\" bc_plus_docs | rg -i \"brother\" | head"
}
```

結果:

```
ナイジェリアでは、現在よりも多くの中小企業が繁栄することになるだろう。我々の調査によると、若年層の卒業生の94.67%が、経済的な支援があればナイジェリアで起業する意向を示している。しかし、卒業生の76.2%は海外への移住を希望していると回答している。現在、Amaeshiら（2018）によると、卒業生が利用できる資金は、海外渡航に必要なビザ申請手続きに充てられている。図111
4.7: 転居を希望する卒業生の割合 卒業生には活用できる機会が数多く存在するが、アマエシ氏によれば、ゼロから事業を立ち上げる準備ができていない人は多いようだ。当レポートでは、以下のことが明らかになった
...
```

結果:

[... 省略、28644文字が省略されました]

ターン5:

推論内容: (検索継続中...)

ツール: Bash

ツール呼び出し:

```
{
  "command": "tmpdir=$(mktemp -d); rg -l -i \"nov(ember)?\\\\s*2023\" bc_plus_docs >
$tmpdir/nov.txt; rg -l -i \"dispute\" bc_plus_docs > $tmpdir/dis.txt; rg -l -i \"director\" bc_plus_docs >
$tmpdir/dir.txt; rg -l -i \"brother\" bc_plus_docs >
$tmpdir/bro.txt; rg -l -i \"actor\" bc_plus_docs > $tmpdir/act.txt; comm -12 <(sort
$tmpdir/nov.txt) <(sort $tmpdir/dis.txt) > $tmpdir/1.txt; comm -12 <(sort $tmpdir/1.txt) <(sort $tmpdir/dir.txt) >
$tmpdir/2.txt; comm -12 <(sort $tmpdir/2.txt) <(sort
$tmpdir/bro.txt) > $tmpdir/3.txt; comm -12 <(sort $tmpdir/3.txt) <(sort $tmpdir/act.txt) > $tmpdir/final.txt; echo
\"count $(wc -l < $tmpdir/final.txt)\"; sed -n '1,200 p' $tmpdir/final.txt"
}
```

結果:

```
count 57
bc\ _plus \ _docs / africacenter. org / アフリカの2024年選挙: 民主主義の勢いを取り戻すための課題と機会 .txt
bc\ _plus \ _docs / archive . blondie . net/ ブロンディ公式サイト ライブ公演リスト.txt bc\ _plus \ _docs
/ brownbagteacher. com / 小学1年生の初日.txt bc\ _plus \ _docs / carnegieendowment. org / 地政学と経
済外交
txt bc\ _plus \ _docs / carnegieendowment.org / 欧州連合における地政学と経済外交.txt bc\ _plus \
_docs / ...
```

ターン6:

推論内容: (検索を続行中...)

ツール: Bash

ツール呼び出し:

```
{
  "command": "rg -n -i \"Marc Coppola\" bc_plus_docs | head"
}
```

結果:

```
bc\ _plus \ _docs / en. wikipedia . org / WPLJ - Wikipedia . txt :59: 1970年代後半になると、WPLJはレッド・ツェッペ
リンなどのハードロック系アーティストを重点的に取り上げる傾向にあった（
（毎晩「Get the Led Out」というコーナーがあった）、カンザス、ボストン、クイーンなどが、競合
局のWNEW-FMに比べて放送回数が少なくなっていた。この時点で、同局はソフトな
ポップソングの放送を減らしたが、聴取率は依然として競合レベルを維持していた。1980年、マーク
・グッドマンがフィラデルフィアからWPLJに移籍し、12月8日の夕方、ジョン・レノンの殺害ニュースが
報じられた際も放送を担当していた。グッドマンはその後まもなく同局を去り.....
ジョン・レノンの暗殺のニュースが飛び込んだ際、生放送中だった。グッドマンは数ヶ月後に同局を去った
.....
```

正解: その映画は**_『ファミリー・マン』(2000)_**です。